# LLM辅助开放同行评议：元评审归纳生成研究

■朱丽雅[1)]　乐小虬[1,2)*]　付　芸[1)]

收稿日期：2024-11-06
修回日期：2024-11-20

1）中国科学院文献情报中心，北京市海淀区北四环西路33号　100190
2）中国科学院大学经济与管理学院信息资源管理系，北京市海淀区北四环西路33号　100190

**摘　要**　**【目的】**探索大语言模型（Large Language Model，LLM）技术在开放同行评议中的应用潜力，结合评审专家意见和作者回复数据，自动生成元评审（Meta-Review），辅助编辑快速归纳评审要点，助推开放同行评议过程向智能化方向发展。**【方法】**基于LLM，利用少样本对比学习、自我反思等提示学习方法，识别评审专家和作者回复的论点和“疑问-回复”论点对，采用分步引导式方法指导LLM自动生成元评审。**【结果】**通过合理的提示学习策略，LLM能够有效识别同行评议中的论点以及“疑问-回复”论点对，生成具有论证性结构的元评审内容，显著提升元评审生成的质量。**【结论】**基于LLM的元评审归纳和生成可为优化开放同行评议流程和提高评审效率提供有效途径。

**关键词**　大语言模型；开放同行评议；元评审；提示学习方法
DOI：10.11946/cjstp.202411061208

开放同行评议以高度透明的评审过程显著增强了评审的公平性和高效性，正逐渐成为一种广受欢迎且发展迅速的同行评议模式[1]。OpenReview、Publons等开放同行评议在线平台通过公开评审意见、为作者与评审专家提供直接交流互动的窗口，突破了传统单盲、双盲评审模式意见交互性差、时间周期长、效率低等局限。这种公开透明的评审模式对评审专家和编辑提出了更高的评审要求。以OpenReview平台为例：每篇提交的论文将由多名评审专家进行推荐性评分，并从多个维度给出评审意见，包括但不限于论文的质量、创新性、数据的可靠性、方法科学性等；作者针对评审意见进行答复，对论文中存在的问题进行解释和补充；最终编辑综合考虑评审专家的意见和作者的回复，撰写一份精简版元评审，交由主编作出最终决策。

根据国际表征学习大会（The International Conference on Learning Representations，ICLR）元评审指南[2]，元评审应清晰、客观地概括论文内容和评审的讨论，为最终决策提供有力支持，具体包括3项要求：（1）简要概括论文的核心论点、研究方法、主要发现，并指出待解决的问题，以展现研究的创新性与局限性；（2）综合评审专家的核心关注点和作者的回复，编辑对问题提出自己的看法，评估哪些意见在决策时具有关键性影响；（3）基于充分的论据提出明确、合理的推荐建议。然而，随着论文投稿数量的增长，评审专家与编辑面临的工作压力不断加剧，如何提升评审效率成为亟需解决的问题。

为了应对上述挑战，研究人员探索利用机器学习或自然语言处理等技术自动生成元评审内容。早期研究中，Bhatia等[3]通过提取核心信息并利用微调的统一语言模型（UniLM）预测论文的接收情况，生成辅助性的元评审内容。Shen等[4]提出一种基于端到端架构的元评审生成方法，通过对评审意见进行句子分类，实现结构可控的元评审内容生成。这些方法为后续研究奠定了基础，但是未充分考虑评审意见与作者回复之间的互动关系。Wu等[5]首次将作者回复论点纳入元评审生成任务，利用图注意力网络建模评审专家与作者的论证结构，实现元评审的自动生成。该方法依赖深度学习模型的训练，在生成结果的准确性和可读性上仍有不足。Zeng等[6]提出基于大语言模型（Large Language Model，LLM）的清单引导自省方法，通过分解任务与迭代反馈生成元评审内容，然而，该研究仍未考虑作者回复的内容。

事实上，在开放同行评议过程中，作者通常会针对评审专家的质疑和建议作出回应，提供补充说明

**基金项目**：国家社会科学基金项目“人工智能赋能的基础研究代表作学术贡献循证评价学科参考系研究”（23BTQ102）。
**作者简介**：朱丽雅（ORCID：0000-0003-3293-6893），硕士，助理研究员，E-mail：zhuly@mail.las.ac.cn；付　芸，博士，馆员。
*通信作者：乐小虬（ORCID：0000-0002-7114-5544），博士，研究员，E-mail：lexq@mail.las.ac.cn。



中国知网　https://www.cnki.net

或进一步解释。评审专家的疑问与作者的回复会形成多个论点对，分散在评审意见和回复文本中。有效利用评审专家与作者回复的论点，基于核心论点自动生成元评审，不仅能够更清晰地呈现论文的核心优缺点，还能帮助编辑更全面、客观地理解论文，提升评审质量和决策的科学性。然而，现有研究多聚焦评审专家的观点总结，缺乏对作者回复内容的深入理解与整合。此外，已有研究主要使用传统的深度学习模型，在理解和整合复杂信息方面存在显著局限性，生成的元评审质量和内容深度仍需进一步提升。

以GPT-4为代表的LLM在语义理解、知识整合、逻辑推理等方面都表现出较强的能力[7]，为人工智能辅助同行评议过程提供了新的技术范式。在研究层面，Liu等[8]和Liang等[9]通过使用不同的提示方法，评估LLM在生成专家评审任务上的可靠性和稳定性。Zhou等[10]利用GPT-3.5和GPT-4实现论文分数预测与评审意见生成。在应用层面，Sun等[11]开发了ReviewFlow模拟专家的同行评议工作流程，利用LLM辅助专家生成评审意见，并对论文进行新颖性的评估，提高评审过程的效率和质量。Jin等[12]提出了基于LLM的同行评议模拟框架AgentReview，通过控制变量的对比实验，模拟同行评议的过程，不仅解决了数据隐私的问题，也为人工智能辅助同行评议提供新的思路。

本文旨在探索基于LLM的元评审自动生成方法，通过设计有效的提示学习策略，从评审专家和作者回复中识别论点、“疑问－回复”论点对以及不同评审专家的核心论点与论点对关系，归纳生成包含论证结构的元评审内容，辅助编辑快速归纳评审要点。研究结果有助于提升开放同行评议模式中编辑的审稿效率，助推开放同行评议过程向智能化方向发展。

## 1　研究方法

### 1.1　元评审归纳生成基本框架

由于评审专家的意见与作者的回复通常篇幅较长且结构复杂，若直接利用LLM在多个文本段落中进行归纳生成，难以准确把握评审专家和作者论证讨论的核心议题。因此，将元评审自动生成任务细分为3个阶段，结合提示工程模板和提示学习策略，提升LLM在复杂评审文本处理中的效果。具体方法流程如图1所示。

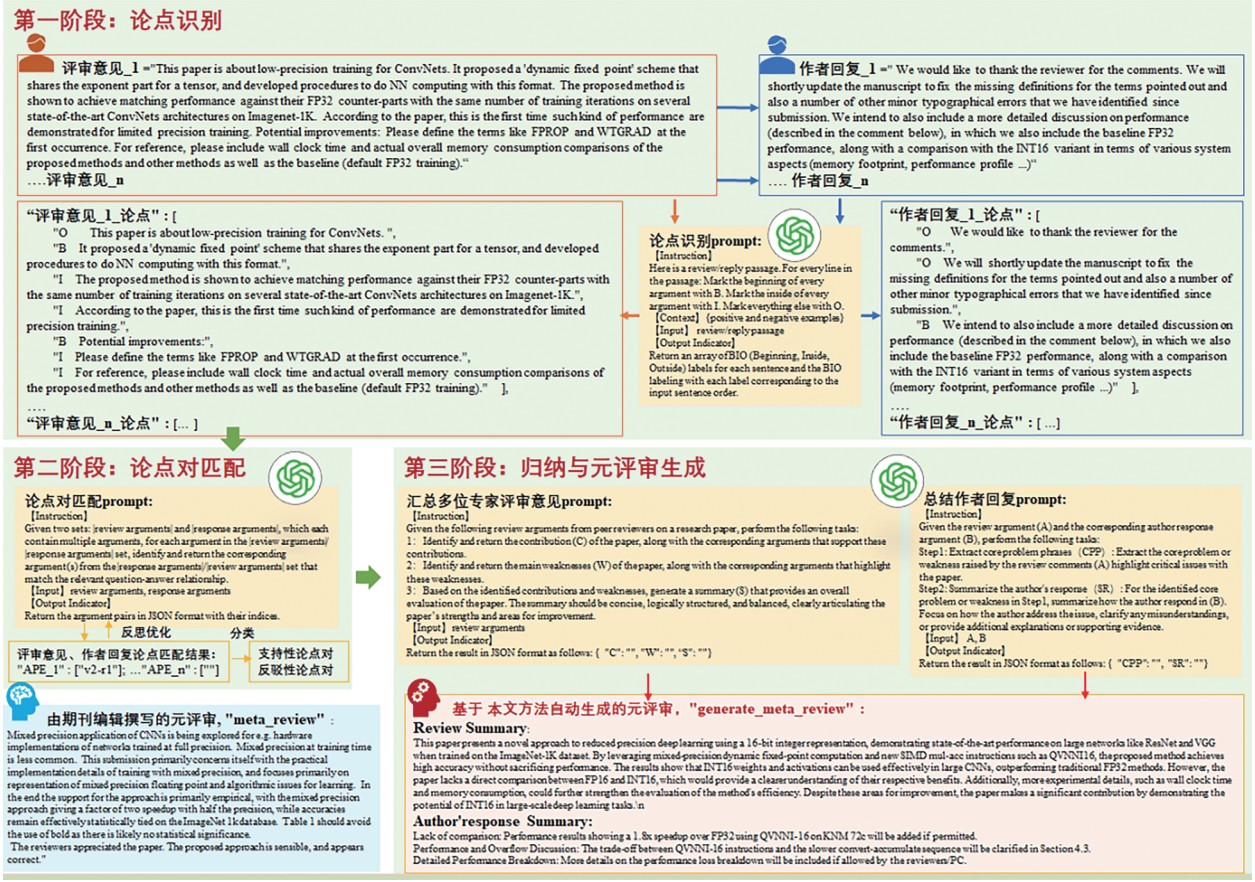



图1　元评审归纳生成基本框架



中国知网 https://www.cnki.net

第一阶段：论点识别。论点是评审专家意见和作者回复中表达论证性的观点或主张。假设给定一组评审专家意见和作者回复的文本段落集合$X=\{p_1, p_2, \cdots, p_n\}$，每个段落$p_i$由若干句子组成，即$p_i=\left\{s_1^{(i)}, s_2^{(i)}, \cdots, s_m^{(i)}\right\}$。论点识别任务的核心是从段落$p_i$中识别出构成论点的一个或多个连续的句子序列$a_j^{(i)}=\left\{s_p^{(i)}, s_{p+1}^{(i)}, \cdots, s_q^{(i)}\right\}$，其中$1\leqslant p\leqslant q\leqslant m$，$a_j^{(i)}$代表段落$p_i$中的第$j$个论点。

第二阶段：论点对匹配。基于评审专家和作者回复的论点，识别“疑问－回复”论点对，并对其关系进行分类。具体地，假设评审专家的论点集合为$V=\{v_1, v_2, \cdots, v_k\}$，作者回复的论点集合为$R=\{r_1, r_2, \cdots, r_l\}$，将$V$和$R$中的论点进行关系匹配，构建“疑问－回复”论点对$(v_i, r_j)$，其中：$v_i\in V$，为评审专家提出的观点或疑问；$r_j\in R$，为作者针对该观点或疑问的回应。在完成论点对匹配后，进一步将匹配的论点对分类为支持性论点对和反驳性论点对。

第三阶段：归纳与元评审生成。对评审专家提出的不同论点进行综合分析，归纳出论文的主要优点和缺点，形成基于评审意见的论文总结。同时，结合论点与反驳性的“疑问－回复”论点对关系，总结作者对评审意见中问题的回应，最终整合生成具有论证结构的元评审内容。

## 1.2　关键技术环节

### 1.2.1　提示工程模板

在3个子任务中，选取GPT-4-0613模型，通过应用程序编程接口（Application Programming Interface，API）调用进行文本理解、推理和归纳生成。为了引导LLM准确理解任务要求、执行任务并生成准确且易于解释的结果，设计两种提示工程模板：在论点识别中，采用少样本（Few-Shot）提示工程模板；在论点对匹配任务和元评审的归纳生成任务中，采用零样本（Zero-Shot）提示工程模板。同时，为了控制LLM输出结果的随机性，在所有子任务中，设置温度控制参数为0.2。

提示工程模板的设计遵循ICIO框架[13]，如图2所示。ICIO框架有4个组成元素：一个必要元素（任务指令）和3个可选元素（上下文、输入数据、输出指示）。

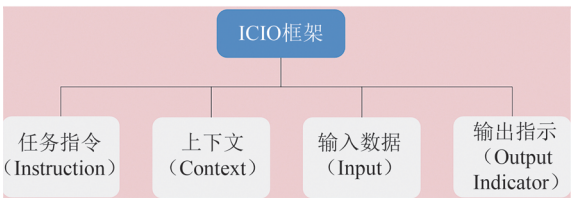



**图2　ICIO提示框架**

任务指令（Instruction）：提供具体的任务说明，明确LLM的任务和目标。

上下文（Context）：提供任务背景或示例，帮助LLM理解上下文。

输入数据（Input）：LLM需要处理的文本内容。

输出指示（Output Indicator）：指定LLM应生成的输出格式，增强输出结果的结构性和可解释性。

### 1.2.2　论点识别

为了确保LLM能够精准识别由一个或多个连续句子组成的论点的边界和结构，将评审专家意见和作者回复中的论点识别问题转化为基于LLM的序列标注问题。在任务指令中，明确要求LLM按照BIO（Beginning，Inside，Outside）标记方案对输入文本进行论点标注，其中“B”表示论点的起始位置，“I”表示论点的内部部分，“O”表示非论点内容。

同时，设计少样本对比学习策略，引导LLM理解任务要求并高效完成标注。具体地，在提示模板的上下文中加入有限数量的正向示例和负向示例。正向示例用于指导LLM识别符合论点特征的句子序列；负向示例则模拟常见的错误标注，明确指出错误类型和正确答案，帮助LLM规避类似错误。正负示例的比例设定为3∶2，即包含3个正向样本和2个负向样本。在获得LLM的初步标注结果后，通过外部程序自动检查标注结果，识别“B-O-I”或以“I”开头的不合法标注，并自动反馈给LLM进行修正。通过多次迭代，逐步优化标注结果。

### 1.2.3　论点对匹配

论点对匹配任务要求LLM识别评审专家评论与作者回复中各论点之间是否存在“疑问－回复”关系。这一任务中，LLM不仅需要深入理解论点的语义，还需要对各个论点之间的潜在关联进行推理。然而，在特定的知识逻辑推理应用中，LLM可能因过度自信或固有偏见，使推理结果出现偏差或多次推理结果不一致。因此，借鉴Zhang等[14]的自我反思的策略，采用前向和后向两个方向进行论点对匹配。通过对比前向和后向的论点对匹配结果，汇总结果差异，并将不同类型的差异反馈给LLM，促使LLM有针对性地对论点对匹配结果进行优化。

具体地，首先，从评论到回复的方向进行前向论点对匹配，识别评论中的论点及其对应的回复论点，生成初步的论点对匹配结果集$R_{\text{fwd}}$。然后，从回复到评论的方向进行后向论点对匹配，识别回复中的论点及其对应的评论论点，生成另一组论点对匹配结果集$R_{\text{bwd}}$。对比两组匹配结果集，通过程序自动识别



中国知网　https://www.cnki.net

前向推理结果$R_{fwd}$和后向推理结果$R_{bwd}$中的论点对缺失和论点对错乱。

（1）论点对缺失：在某一方向上，匹配结果集中论点$v_i$和论点$r_j$存在“疑问-回复”关系，但在相反的方向上，未找到任何与论点$v_i$和论点$r_j$相关的“疑问-回复”关系。例如，$R_{fwd}=\{(v_1,r_1),(v_2,r_2),(v_3,r_3),\cdots\}$，$R_{bwd}=\{(v_2,r_2),(v_3,r_3),\cdots\}$，在$R_{bwd}$方向上无法找到$(v_1,r_1)$论点对关系。

（2）论点对错乱：在某一方向上，匹配结果集中论点$v_i$和论点$r_j$存在“疑问-回复”关系，但在相反的方向上，论点$v_i$或论点$r_j$和其他论点存在“疑问-回复”关系。例如，$R_{fwd}=\{(v_1,r_1),(v_2,r_2),(v_3,r_3),\cdots\}$，$R_{bwd}=\{(v_1,r_1),(v_2,r_2),(v_4,r_3),\cdots\}$，$R_{fwd}$中的$(v_3,r_3)$和$R_{bwd}$中的$(v_4,r_3)$形成错乱的匹配关系对。

针对缺失的论点对，要求LLM重新确认是否存在“疑问-回复”关系；针对错乱的论点对，将错误内容反馈给LLM，并重新执行论点对匹配。最后，基于LLM对作者回复的论点进行分析，判断作者是表达了对评审专家观点的认同，还是对评审专家的评论作出解释或反驳，进一步将“疑问-回复”类型的论点对分为支持性论点对和反驳性论点对。

1.2.4　元评审归纳与生成

基于专家评审意见与作者回复的论点和论点对识别结果，提出一种分步引导式的方法来自动归纳并生成元评审内容，具体步骤如表1所示。首先，利用LLM汇总多位专家的评审意见，提炼出反映论文主要优缺点的关键论点，并在此基础上概括生成对论文的总体评价。随后，针对论文中的缺点，关联其反驳性论点对，通过LLM识别评审专家陈述的核心问题，并总结作者对核心问题的回复。最后，将核心问题和对回复内容的总结整合到论文总体评价中，形成具有论证结构的元评审内容。

**表1　分步引导式元评审归纳生成方法**

| 目标 | 步骤 |
|---|---|
| 归纳不同评审专家论点，生成总体评价 | 输入：不同评审专家的论点<br>输出：总体评价{CONTRIBUTIONS，WEAKNESSES，SUMMARY} |
| 对于总体评价中的各个缺点，关联反驳性论点对，识别核心问题，并归纳作者回复 | 输入：论文的主要缺点和“疑问-回复”论点对<br>判断：对于每个缺点，是否存在关联的反驳性论点对？如果存在，则实施以下操作<br>（1）识别评审专家的核心问题（Core_Problem）<br>（2）归纳作者对问题的回复（Clarification）<br>（3）将{Core_Problem：Clarification}结构保存<br>输出：包含核心问题和作者回复的总结 |
| 形成最终的元评审 | 将总体评价和作者回复的总结汇总 |

## 2　实验过程与结果分析

### 2.1　实验数据

从OpenReview平台上收集2018—2019年ICLR的同行评议数据，经过筛选，剔除缺少作者回复或评审专家少于两人的数据，最终获得1823篇论文的完整评审数据。每篇论文的评审数据包括论文标题、年份、专家评审、专家评分、作者回复、主编撰写的元评审以及最终决策等信息。

### 2.2　实验设计

为了验证论点和论点对匹配的效果，实验选取传统的深度学习方法MT-H-LSTM-CRF[15]、MLMC[16]和MRC-APE[17]进行对比实验。为确保实验结果的可靠性，采用基准数据集RR-submission-v2[15]进行效果验证，该数据集来源于OpenReview平台，包含4764对带有BIO论点标签和论点对关系的专家评审与作者回复数据。此外，为了进一步评估提出的提示学习策略的有效性，设计了零样本（Zero-Shot）、单样本（One-Shot）和思维链（Chain-of-Thought）等提示学习策略，并与所提方法进行对比实验。

在对比实验中，数据集按照8∶1∶1的比例随机拆分，划分为训练集、验证集和测试集，用于传统深度学习模型的模型训练、参数优化和性能评估。对于基于LLM的方法，无需训练过程，直接使用测试集数据进行实验。

在元评审归纳生成实验中，选择传统的摘要生成方法LexRank[18]和元评审生成的基线方法MReD[4]作为对比模型。其中，MReD利用自带的专用标注数据集进行模型训练，并在本研究收集的评审数据上进行测试，生成的元评审内容涵盖总结、优点、缺点和建议4个方面。

### 2.3　评估方法

在论点和论点对识别子任务中，采用F1值作为评估指标，衡量论点识别和论点对匹配结果的精确率与召回率的加权平均值，计算公式为

$$S_{F1}=2\cdot\frac{P\cdot R}{P+R}\tag{1}$$

式中：$P$代表论点识别或论点对匹配的精确率；$R$代表论点识别或论点对匹配的召回率。

在元评审生成任务中，采用量化评估与人工评分相结合的综合评估方法。在量化评估中，参考文本生成和自动摘要领域的评价标准，选择ROUGE-1[19]、ROUGE-2[19]、ROUGE-L[19]和BERTScore[20]等指标计算归纳生成的元评审与真实元评审的差距。其



中国知网　https://www.cnki.net

中，ROUGE-1 和 ROUGE-2 分别用于评估生成文本与参考文本在单个词、相邻的两个词组成的词组上的重叠情况，ROUGE-L 通过计算最长公共子序列来量化评估生成文本与参考文本之间的相似度。BERTScore 则基于上下文嵌入技术，从语义层面评估生成文本与参考文本的相似度。

在人工评分中，设定了 4 项评分指标，评分范围为 1~5 分，其中 1 分表示最低评分，5 分表示最高评分。具体评分标准如下。

（1）观点覆盖性：是否涵盖了评审专家与作者双方的核心观点。

（2）意图准确性：是否准确传达了评审专家和作者的情感倾向。

（3）观点客观性：在归纳多方观点时，是否保持客观公正。

（4）实用性与决策支持：是否能为同行评议过程提供有效参考和决策支持。

### 2.4　结果分析

#### 2.4.1　论点与论点对识别结果

表 2 展示了不同方法在论点和论点对识别任务中的 F1 值结果。本文方法在论点识别任务中表现出与其他基线模型相当的效果，且 F1 值高于 MT-H-LSTM-CRF 和 MLMC。在论点对识别任务上，F1 值为 41.29%，明显优于其他方法，表明设计了合理的提示学习方法，LLM 能够在同行评议的论点和论点对识别中展现良好的性能。

**表2　论点和论点对识别性能对比**

| 模型 | F1 值 /% | |
|---|---|---|
| | 论点 | 论点对 |
| MT-H-LSTM-CRF | 70.12 | 26.46 |
| MLMC | 71.35 | 32.81 |
| MRC-APE | 72.43 | 39.92 |
| Zero-Shot（GPT-4） | 60.57 | 28.23 |
| One-Shot（GPT-4） | 64.98 | 31.10 |
| Chain-of-Thought（GPT-4） | 65.33 | 32.56 |
| 本文方法 | 71.94 | 41.29 |

同时，相比其他 LLM 策略，本文方法表现出更好的实验效果，验证了少样本对比学习和自我反思学习策略的有效性，进一步表明在有效的提示策略下，LLM 能够为同行评议的文本理解提供强有力的支持，具有较高的应用价值。

#### 2.4.2　元评审归纳生成结果

从 OpenReview 平台收集的元评审数据未直接包含作者回复内容，因此，在量化评估时，将前期 LLM 基于专家评审论点生成的总体评价结果和基于 LexRank、MReD 方法的生成结果进行对比，各项评估指标的对比结果如表 3 所示。

**表3　元评审归纳生成结果对比**

| 方法 | ROUGE-1 | ROUGE-2 | ROUGE-L | BERTScore |
|---|---|---|---|---|
| LexRank | 0.29 | 0.07 | 0.27 | 0.53 |
| MReD | 0.35 | 0.09 | 0.28 | 0.69 |
| 本文方法 | 0.43 | 0.06 | 0.25 | 0.88 |

对比结果显示，在基于专家评审论点生成的总体评价结果中，本文构建的提示工程方法在 ROUGE-1 和 BERTScore 指标上明显优于 LexRank 和 MReD 方法，这表明 LLM 具备较强的上下文理解能力，能够更准确地识别评审专家意见的重要信息，生成文本与元评审在内容上高度相关。然而，在 ROUGE-2、ROUGE-L 指标上的得分低于其他两种方法，出现这一结果的原因是：不同于抽取式方法，基于 LLM 的生成方法通过对评审专家的论点进行综合分析与归纳，生成新的文本，生成文本的语序和用词可能与原文存在差异，但所表达的语义是一致的。

为了全面评估 LLM 在元评审归纳生成方面的有效性，以及基于论点、论点对结构，整合作者回复内容的元评审内容的合理性，实验中特别邀请 3 名志愿者对随机挑选的 50 篇元评审归纳生成结果进行评分。图 3 展示了不同方法在观点覆盖性、意图准确性、观点客观性和实用性与决策支持 4 项指标上的得分情况。

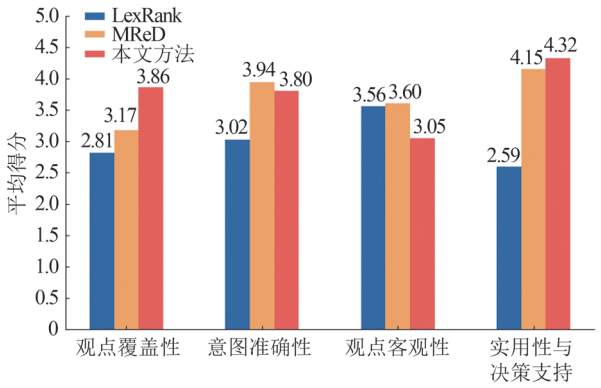



**图3　元评审的人工评估结果**

结果显示，本文提出的方法在观点覆盖性、实用性与决策支持方面的平均得分高于其他两种方法。这表明，基于 LLM 的归纳生成方法在整合评审专家意见与作者回复时，能够涵盖双方的核心观点，准确理解并传达各方的主张，可为开放同行评议决策提供有价值的参考。在意图准确性上，本文方法的平均得分与最高得分相差 0.14，差距相对较小。在观点客观性方面，本文方法的平均得分最低，说明方法



中国知网　https://www.cnki.net

在归纳多方观点时存在一定的主观倾向。未来研究可以考虑引入更多的平衡机制，确保在整合不同意见时保持中立。

### 2.5　案例分析

根据人工评估的结果，对LLM归纳生成的元评审内容进行分析，如图4所示。元评审中归纳了不同评审专家的意见，生成了论文的总体评价，并基于论文存在的主要缺点，简要凝练了作者对专家意见的回复，生成了具有论证结构的元评审。通过分析具体指标，得出以下几点发现。




图4　元评审生成结果示例

（1）归纳生成的元评审内容逻辑清晰、语义表达精准，能够充分反映论文的优点与缺点。

（2）整合作者回复内容的元评审归纳生成结果直观呈现了评审专家与作者的论证过程，能够揭示论文的核心问题和争议，有助于编辑快速理解论文并作出决策。

（3）LLM在归纳生成过程中可能产生主观性的描述，例如，评审专家在陈述论文主要工作时指出："This work proposed a simple but strong baseline for parametric texture synthesis." 而LLM在此基础上增加了未经验证的主观评价："The paper makes a significant contribution by proposing a simple yet powerful baseline for parametric texture synthesis." 从论文创新性或贡献度评价的角度来看，若评审专家未提供相关评价，论文的贡献度应由编辑、主编或后续研究者进行评估，错误地引入主观性描述可能会导致对论文价值的误解，影响最终决策的客观性和公正性。

（4）在专家评审论点数量较多的情况下，LLM更关注内容详细或篇幅较长的论点，忽略简短却同样重要的论点。尤其在评审专家意见存在分歧时，可能会过度偏向某一方，导致归纳生成的内容不均衡、不全面、不客观。

（5）由于评审专家可能持有不同的意见，作者



中国知网　https://www.cnki.net

回复也可能过于笼统或者回避核心问题。在撰写元评审时，编辑或主编凭借其专业背景，能够提出独到见解，并对不同论点进行权衡、总结，形成最终的决策意见。相比之下，LLM缺乏对论点的判断能力，无法完全替代专业评审，因此，其生成的内容不能视为最终的元评审，只能发挥辅助作用，汇总有参考价值的观点，一定程度上支持编辑的元评审撰写和最终决策。

## 3 元评审的归纳生成对期刊论文评审发展的推动作用

同行评议是科研质量保障的核心环节，其效率与透明度对学术评价的公正性和权威性至关重要。随着开放科学的迅速发展，智能化技术的引入为传统同行评议制度优化提供了新的契机，特别是在国内期刊逐步探索开放同行评议模式的过程中，相关技术的应用展现出重要的推动作用。本文研究的元评审自动归纳生成作为LLM赋能期刊同行评议的典型场景，为期刊评审向开放、高效、智能化方向发展提供了有力支持，主要体现在以下3个方面。

（1）评审与反馈过程呈现出动态、即时特征。在开放同行评议模式下，不同评审专家与作者在不同时段就论文中的共性或差异性问题进行问答，元评审归纳的结果能够实时生成，动态呈现评审专家与作者在关键问题上的论证状态与结果，期刊编辑无需翻看繁琐细节即可把握整体评审状况，大幅提高工作效率。

（2）提升评审结果的客观性，有效应对多学科交叉带来的挑战。随着学术研究的交叉与融合日益增强，论文内容常常涉及多学科背景，需要不同领域的专家参与评审。元评审的自动归纳能够综合不同学科评审专家对论文的评价、质疑和作者的回复等多元信息，生成的评审结果更全面，可信度更高，能够避免单一视角带来的主观偏差，提升跨学科交流的质量与效率。

（3）有助于推动开放同行评议模式的落地。目前，开放同行评议模式在国内的应用仍处于探索阶段，其中一个关键挑战在于其实施难度较大，期刊编辑需要投入大量时间来整理和理解不同专家与作者问答过程，综合评估论文的质量，并撰写元评审内容，这影响了开放同行评议的效率。因此，构建元评审内容自动生成工具能够有效缓解这一问题，为开放同行评议模式的高效运作提供技术保障，从而推动开放同行评议模式的落地。

## 4 结论

本文探索了LLM在开放同行评议中自动生成元评审的方法。通过设计少样本对比学习和自我反思学习的提示学习策略，增强LLM对复杂同行评议数据的理解，识别出同行评议中的论点和“疑问-回复”论点对，利用LLM的文本归纳能力提炼并生成了元评审内容。研究方法克服了传统的单纯依赖评审专家观点进行摘要生成的局限，通过深入分析评审专家与作者的互动性论证过程，分步引导LLM归纳核心论点，并结合反驳性“疑问-回复”论点对，自动生成包含论证过程的元评审内容，直观展示论文的总体性评价、核心问题以及争议。研究结果可进一步提升同行评议的效率，辅助编辑快速纵览不同评审专家意见与作者观点，助推开放同行评议的智能化进程。

## 参考文献


[1] Armstrong J S. Barriers to scientific contributions: The author's formula[J]. *Behavioral and Brain Sciences*, 1982, 5(2): 197-199.

[2] Meta-review guidelines[EB/OL]. [2024-08-09]. https://iclr.cc/Conferences/2021/MetareviewGuide.

[3] Bhatia C, Pradhan T, Pal S. MetaGen: An academic meta-review generation system[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval, July 25-30, 2020, Virtual Event China. New York: ACM Press, 2020: 1653-1656.

[4] Shen C H, Cheng L Y, Zhou R, *et al*. MReD: A meta-review dataset for structure-controllable text generation[EB/OL]. (2021-10-14)[2024-08-09]. https://arxiv.org/abs/2110.07474v6.

[5] Wu P C, Yen A Z, Huang H H, *et al*. Incorporating peer reviews and rebuttal counter-arguments for meta-review generation[C]//Proceedings of the 31st ACM International Conference on Information & Knowledge Management, October 17-21, 2022, Atlanta, GA, USA. New York: ACM Press, 2022: 2189-2198.

[6] Zeng Q, Sidhu M, Blume A, *et al*. Scientific opinion summarization: Paper meta-review generation dataset, methods, and evaluation[EB/OL]. (2023-05-24)[2024-08-15]. https://arxiv.org/abs/2305.14647.

[7] Achiam J, Adler S, Agarwal S, *et al*. GPT-4 technical report[EB/OL]. (2023-03-15)[2024-08-09]. https://arxiv.org/abs/2303.08774.

[8] Liu R, Shah N B. ReviewerGPT? An exploratory study on using large language models for paper reviewing[EB/OL]. (2023-06-01)[2024-08-08]. https://arxiv.org/abs/2306.00622v1.

[9] Liang W X, Zhang Y H, Cao H C, *et al*. Can large language models provide useful feedback on research papers? A large-scale empirical analysis[J]. *NEJM AI*, 2024, 1(8): 2400196.

[10] Zhou R Y, Chen L, Yu K. Is LLM a reliable reviewer? A comprehensive evaluation of LLM on automatic paper reviewing




中国知网 https://www.cnki.net

tasks[C]// Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024), May 20-25, 2024, Torino, Italy. Paris: ELRA and ICCL, 2024: 9340-9351.

[11] Sun L, Chan A, Chang Y S, *et al*. ReviewFlow: Intelligent scaffolding to support academic peer reviewing[C]// Proceedings of the 29th International Conference on Intelligent User Interfaces, March 18-21, 2024, Greenville, SC, USA. New York: ACM Press, 2024: 120-137.

[12] Jin Y Q, Zhao Q L, Wang Y Y, *et al*. AgentReview: Exploring peer review dynamics with LLM agents[EB/OL]. (2024-06-18)[2024-08-09]. https://arxiv.org/abs/2406.12708v2.

[13] Prompt engineering guide[EB/OL]. [2024-08-20]. https://github.com/dair-ai/Prompt-Engineering-Guide/blob/main/guides/prompts-intro.md.

[14] Zhang W Q, Shen Y L, Wu L J, *et al*. Self-contrast: Better reflection through inconsistent solving perspectives[EB/OL]. (2024-01-04)[2024-08-09]. https://arxiv.org/abs/2401.02009v3.

[15] Cheng L Y, Bing L D, Yu Q, *et al*. APE: Argument pair extraction from peer review and rebuttal via multi-task learning[C]// Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP), November 16-20, 2020, Online. Stroudsburg: Association for Computational Linguistics, 2020: 7000-7011.

[16] Cheng L Y, Wu T Y, Bing L D, *et al*. Argument pair extraction via attention-guided multi-layer multi-cross encoding[C]// Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers), August 1-6, 2021, Online. Stroudsburg: Association for Computational Linguistics, 2021: 6341-6353.

[17] Bao J Z, Sun J Y, Zhu Q L, *et al*. Have my arguments been replied to? Argument pair extraction as machine reading comprehension[C]// Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers), May 29-35, 2022, Dublin, Ireland. Stroudsburg: Association for Computational Linguistics, 2022: 29-35.

[18] Erkan G, Radev D R. LexRank: Graph-based lexical centrality as salience in text summarization[J]. *Journal of Artificial Intelligence Research*, 2004, 22: 457-479.

[19] Lin C Y. ROUGE: A package for automatic evaluation of summaries[C]// Proceedings of Workshop on Text Summarization of ACL, 2004.

[20] Zhang T Y, Kishore V, Wu F, *et al*. BERTScore: Evaluating text generation with BERT[EB/OL]. (2019-04-21)[2024-09-17]. https://arxiv.org/abs/1904.09675v3.

**作者贡献声明：**

朱丽雅：进行实验，撰写、修改论文；

乐小虬：提出研究方向，指导论文撰写，修改论文；

付　芸：分析实验，修改论文。

# LLM assisted open peer review: A study on meta-review generation

**ZHU Liya[1)], LE Xiaoqiu[1,2)*], FU Yun[1)]**

1) National Science Library, Chinese Academy of Sciences, 33 Beisihuan Xilu, Haidian District, Beijing 100190, China

2) Department of Information Resources Management, School of Economics and Management, University of Chinese Academy of Sciences, 33 Beisihuan Xilu, Haidian District, Beijing 100190, China

**Abstract**: [**Purposes**] This study aims to explore the potential application of large language model (LLM) technology in open peer review. By combining the opinions of review experts and the response data of authors, a meta-review is automatically generated to assist editors in quickly summarizing the key points of review and promote the development of the open peer review process in an intelligent direction. [**Methods**] Based on the LLM, we utilized prompt learning methods such as few-shot contrastive learning and self-reflection to identify the arguments and "problem-reply" argument pairs between review experts and authors, and used a step-by-step guidance method to guide the model to automatically generate meta-review. [**Findings**] Through a reasonable prompt learning strategy, the LLM can effectively recognize the arguments and "problem-reply" argument pairs and generate meta-review content with an argumentative structure, which remarkably enhances the quality of meta-review generation. [**Conclusions**] Meta-review induction and generation based on LLM can offer an effective approach for optimizing the open peer review process and increasing the review efficiency.

**Keywords**: Large language model; Open peer review; Meta-review; Prompt learning

（本文责编：杨恒）



中国知网　https://www.cnki.net