

系统仿真学报
Journal of System Simulation
ISSN 1004-731X,CN 11-3092/V

《系统仿真学报》网络首发论文

题目：基于知识与大语言模型的高速环境自动驾驶决策研究
作者：王祥，谭国真
DOI：10.16182/j.issn1004731x.joss.24-0065
收稿日期：2024-01-06
网络首发日期：2024-05-08
引用格式：王祥，谭国真. 基于知识与大语言模型的高速环境自动驾驶决策研究[J/OL]. 系统仿真学报. https://doi.org/10.16182/j.issn1004731x.joss.24-0065



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2024-05-08 11:54:12
网络首发地址：https://link.cnki.net/urlid/11.3092.V.20240507.2110.004

系统仿真学报©
Journal of System Simulation

基于知识与大语言模型的高速环境自动驾驶决策研究

王祥，谭国真
大连理工大学 计算机科学与技术学院，辽宁 大连 116081

摘要：针对当前自动驾驶系统缺乏持续学习和可解释性问题。提出具有认知、泛化和学习能力的决策模型，利用大语言模型(Large Language Model, LLM)、注意力机制理解和解释驾驶场景，通过模拟人类驾驶行为和决策过程，实现对驾驶经验的积累和学习并根据驾驶经验不断提升决策能力。在仿真环境中闭环测试决策模型在高速场景的应用，仿真结果表明：知识驱动模型决策成功率比规则和数据学习方法提高了 7%和 4%，具备泛化和可解释能力，提高了自动驾驶系统的可信度和安全性。

关键词：驾驶经验；大语言模型；注意力机制；可解释性；知识驱动
中图分类号：TP391.9　　文献标志码：A
DOI: 10.16182/j.issn1004731x.joss.24-0065

Research on Decision-making of Autonomous Driving in Highway Environment Based on Knowledge and Large Language Model

Wang Xiang，Tan Guozhen
Department Of Computer Science and Technology, Dalian University of Technology, 116081, China

Abstract: Aiming at the lack of continuous learning and interpretability of current autonomous driving system. A decision model with cognition, generalization and learning ability is proposed. LLM and attention mechanism are used to understand and explain driving scenes. By simulating human driving behavior and decision-making process, driving experience can be accumulated and learned, and decision-making ability can be continuously improved according to driving experience. In the simulation environment, the closed-loop test decision model is applied in high-speed scenarios, and the simulation results show that the success rate of the knowledge-driven model is 7% and 4% higher than that of the rules and data learning methods, and it has the generalization and interpretability ability, which improves the reliability and safety of the automatic driving system.

Keywords: driving experience; LLM; attention mechanism; interpretability; knowledge-driven

引言

随着车载传感器技术、机器学习和人工智能快速进步以及高精度地图和定位技术的不断革新，自动驾驶技术迅猛发展[1]，各国都在积极研发自动驾驶技术，并制定了多项法规政策以推动其发展[2]。尽管自动驾驶技术取得了显著成果，但依然面临挑战，对数据驱动方法过于依赖可能导致系统产生数据偏差，进而造成对训练数据的过度拟合，限制系统适应新环境的能力[3]。成熟的自动驾驶系统必须具有可解释性，以获得各界认可，使其能够进行有

收稿日期：2024-01-06　　修回日期：2024-04-10
基金项目：国家自然科学基金重点项目(U1808206)
第一作者：王祥(1997-)，男，博士研究生，研究方向为深度学习与自动驾驶决策。E-mail：DrWangXiang@mail.dlut.edu.cn

针对性的优化和迭代改进。数据驱动的端到端[4]、深度强化学习[5]、模仿学习[6]等算法常被视为黑盒子，无法分析其决策过程，因此如何为决策过程提供解释成为一大挑战。这一挑战限制了自动驾驶系统是否能做出正确决策的能力和进一步优化的潜力。解决数据偏差、泛化以及缺乏可解释性等挑战仍然是自动驾驶研究、开发和部署的关键问题。

规则驱动的方法依赖细致的逻辑推理或使用人工制定的大量规则进行验证。这些方法旨在编写现实世界中特定的观察现象以促进场景理解[7]。目前技术人员制定的规则和收集大量车辆的行驶数据不能处理高度复杂的学习任务，而且现实世界的复杂性和多样性给这些方法带来了明显的局限性，当遇到临时封路或禁行区域时，制定的规则将不再适用，无法解决临时性和突发性的海量数据，这导致传统的基于规则和模块化的自动驾驶系统面临性能瓶颈和优化困难等问题。

文献[8]研究了用于车辆驾驶的行为克隆算法，提出了行为学习智能体模仿专家的行为决策。行为克隆通常被实现为一种监督学习，因此很难适应新的未学习过的情况。文献[9]提出了一种自动驾驶汽车领域的架构，利用端到端的方式训练卷积神经网络用于将单个前置相机的原始图像直接映射为驾驶动作。通过使用专家人类相对较小的训练集，该系统学会在车道标记的局部路段和高速公路上驾驶车辆，该网络能成功检测道路的图像表示而无需显式训练。文献[10]将逆向强化学习应用于自动驾驶决策，以通过人类驾驶员的演示来学习用于实现舒适驾驶的轨迹优化。使用 Deep Q-network 作为逆向强化学习中的提炼步骤来计算奖励，以学习类似人类的驾驶变道行为[11]。

数据驱动的方法以海量数据和计算能力为支撑，建立人类思维过程和探索的连通性系统[12]。然而，数据驱动的算法处理的学习空间与人类认知系统的语义空间存在很大差异，此外，不可避免地会遇到数据偏差和灾难性遗忘现象。

知识驱动的自动驾驶涉及对场景的理解，基于知识的理解，使其能够处理各种复杂的驾驶场景并适应不断变化的环境。这种理解涉及注意力机制、语义理解和环境中上下文感知关系推理，以解决复杂问题，而 LLM 具有这种能力。LLM 基于 Transformer 模型研发，具有数几百上千亿甚至更多参数，并在大量文本数据集上进行训练，能够理解自然语言并执行广泛的复杂任务。根据中国科技部“新一代人工智能发展研究中心”发布的《中国人工智能大模型地图研究报告》[13]显示，我国研发的 LLM 数量排名全球第二，目前 10 亿参数规模以上的 LLM 已发布 79 个，全国 14 个省市在大力开展 LLM 研发，LLM 已经应用于作战仿真[14]、具身智能[15]和计算机视觉[16]等领域。鉴于此，本文首次利用由清华大学提出的 ChatGLM[17]作为决策器对不同驾驶员智能体进行规划并持续积累驾驶经验，将驾驶经验、知识和推理技术结合实现对复杂驾驶场景的准确理解和实时响应，为安全、智能的自动驾驶决策提供了技术支持。

1 知识驱动决策模型

知识驱动决策模型(Knowledge-driven model, KDM)将驾驶场景的丰富信息导入到知识增强模块与交通规则和驾驶等知识相结合理解场景信息，这些信息在场景语义空间转化为知识，语义空间将捕捉场景中各个车辆的目的、驾驶行为等信息。知识模块来解释场景中的具体信息并转化为通用的知识形式，通过知识映射对驾驶场景进行深入推理，在映射过程中利用先前学习到的知识和驾驶经验来理解新的场景做出决策，如图 1 所示。这种方法能从丰富的经验中获得持续学习的能力。

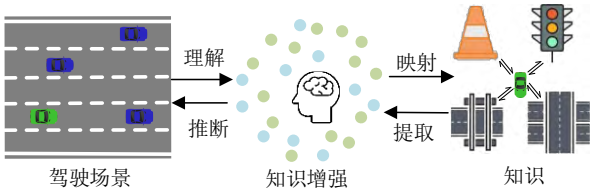


图 1 知识驱动决策模型
Fig.1 Knowledge driven decision model

1.1 注意力机制

在道路上行驶的车辆状态可以用连续位置、航向和速度描述。本车设为 s_0，其他 N 辆环境车辆的联合状态可以用车辆状态列表来描述，如式(1)所示，利用特征列表如式(2)所示，用最少的信息来描述驾驶场景，其中 i 表示车辆标号，j 表示车道线标号，x 和 y 表示位置，v_i^x 和 v_i^y 分别表示横向速度和纵向速度，Line_j 表示所在车道信息。

$$s=\left(s_i\right)\ i\in[0,N] \tag{1}$$

$$s_i=\left[x_i\ y_i\ v_i^x\ v_i^y\ \mathrm{Line}_j\right]^T \tag{2}$$

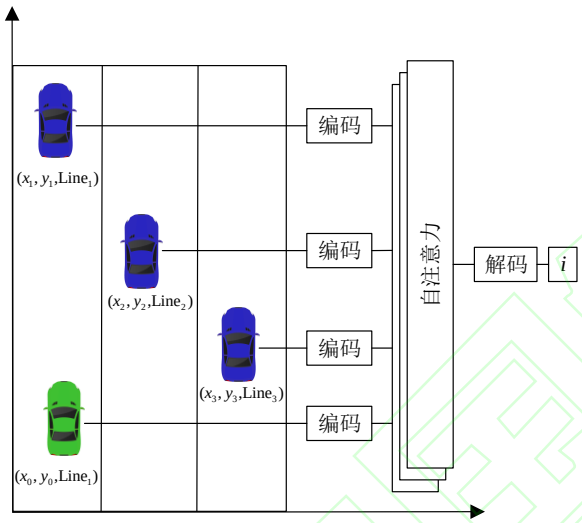


图 2　注意力机制架构

Fig.2　Attention mechanism architecture

注意力机制的总体架构如图 2 所示，它由几个线性相同的编码器、多个注意头和一个线性解码器组成。多个车的特征编码后送入自注意力层，解码后只有一个与本车对应的输出，即影响本车决策的车辆编号列表。

为了根据环境上下文选择车辆子集，本车首先发出一个查询 $Q=[q_0]\in\mathbb{R}^{1\times d_k}$，用其嵌入的线性投影计算 $L_q\in\mathbb{R}^{d_x\times d_k}$。定义一组键如式(3)所示，

$$K=[k_0,\ldots,k_N]\in\mathbb{R}^{N\times d_k} \tag{3}$$

其中包含每辆车的描述性特征 k_i。查询 q_0 和键 k_i 之间的相似性通过它们的点积 $q_0k_i^T$ 评估。然后用平方反比定律对这些相似性进行缩放，并用 softmax 函数对车辆进行归一化，得到注意力矩阵，用它来收集一组输出值 $V=[v_0,\ldots,v_N]$，其中每个值 v_i 是通过共享线性投影 $L_v\in\mathbb{R}^{d_x\times d_v}$ 计算的特征。每个头的注意力如式(4)所示。

$$\mathrm{head}=\mathrm{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{4}$$

将得到的输出解码成车辆编号 i，如式(5)所示，其中 f 表示映射函数，将本车和感兴趣区域重点关注的临近车辆信息输入到经验检索模块，降低冗余信息。

$$i=f\left(head\right) \tag{5}$$

1.2 经验检索

如图 4 所示，利用向量数据库搜索算法检索经验记忆中最相似的过去驾驶场景和经验。将输入查询和内存中的每条记录编码，然后通过嵌入空间中的 k-近邻算法(K-NN)[18]检索出若干个相似记录，再根据与查询的相关性对这些记录进行排序，选择排序最高的历史轨迹，如式(6)所示，其中 act_X 表示要执行的动作，$\mathrm{past}_X\left(X=1,2,3...\right)$ 表示过去的经验动作。

$$act_X=\max\{\mathrm{past}_1,...\mathrm{past}_I,...,\mathrm{past}_X\} \tag{6}$$

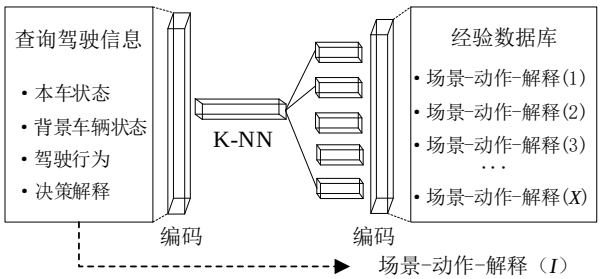


图 4　场景检索

Fig.4　Scene search

1.3 决策模块

知识驱动决策模块包括注意力机制、基于 LLM 的驾驶任务决策器、多驾驶员智能体和向量数据库检索技术，能够模仿学习人类对现实世界的深刻理解，从丰富的经验中获得学习推理能力。

在场景理解中，模型可以过滤信息，只考虑与动作决策相关的信息，利用注意力机制重点关注与

规划路线接近或冲突的车辆。决策器利用自然语言作为统一的接口，基于语言的知识和推理能力利用 LLM 作为系统组件之间的交互式调度程序，改变了传统的感知-预测-规划框架，决策器通过思维链推理来识别关键对象和事件。

如图 3 所示，在收集必要的环境信息后，将本车信息和注意力机制筛选出感兴趣区域的车辆信息作为查询数据，在经验数据中搜索相关的交通法规和最相似的过去驾驶经验，为 LLM 提供提示信息。根据检索到的交通规则和驾驶经验，以及以前收集的环境信息作为提示信息，用作 LLM 的推理引擎的输入。通过多轮对话，LLM 最终收集了有关当前环境的所有必要信息。推理引擎根据输入进行多轮推理，LLM 通过调用智能体库中的特定驾驶行为智能体，将询问 LLM 是否需要激活特定模块，如果 LLM 决定激活一个模块，将向 LLM 提供与该模块相关的函数，当 LLM 决定调用相关函数时，模块才会被激活。驾驶行为智能体通过运动规划来生成驾驶轨迹，再由对应的智能体根据运动学完成具体的变道、跟车、加速和减速等动作。由于 LLM 会偶尔出现幻觉导致车辆发生碰撞事故，所以将决策失误的场景进行修正，通过专家监督保证决策的安全性后再添加到数据库中。这种协同整合的模块组合更像驾驶员学习驾驶过程一样，有更强的学习能力。

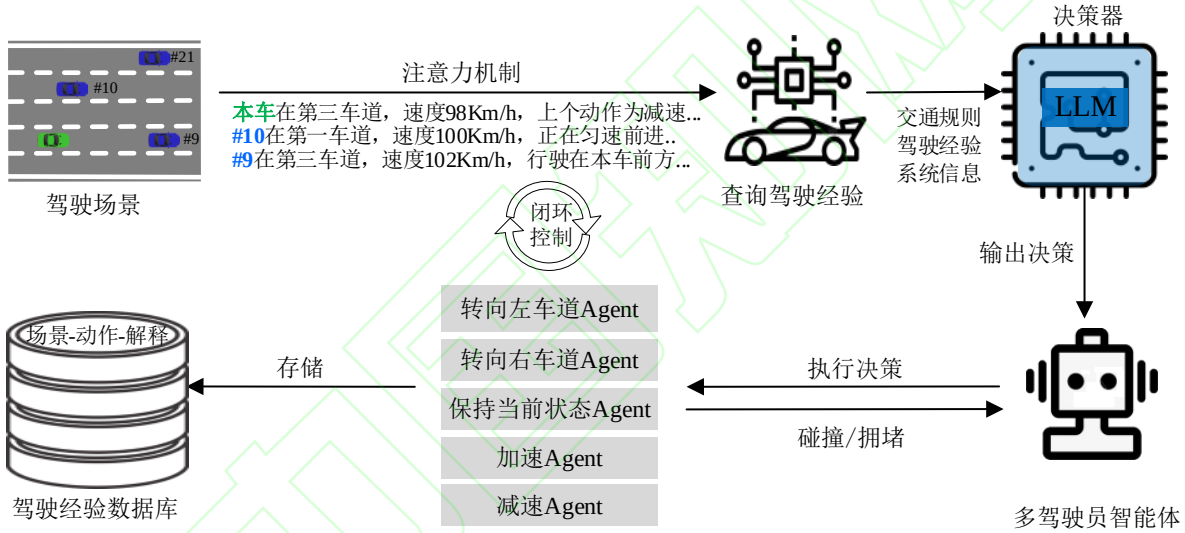


图 3　决策模块总体架构

Fig.3　Overall architecture of decision-making module

2　仿真实验

2.1　实验环境设置

在 Highway-Env[19]仿真环境中，利用感知工具观察环境并做出决策控制车辆，形成闭环。Highway-Env 提供了一个灵活的仿真环境，可根据用户需求进行定制，可定义路网拓扑结构、车辆初始参数、道路标志，还可以修改参数并支持多种场景和交通情况，包括多车道高速公路、交叉口和并线。Highway-Env 的闭环驾驶要求知识驱动模型在每个时间步都做出安全决策，并保持决策之间的一致性，避免频繁加减速和无意义变道等行为。计算机配置为：Ubuntu20.4 操作系统，i7-14700KF 处理器，内存 32 GB，GPU 为 GeForce RTX 4080Ti。

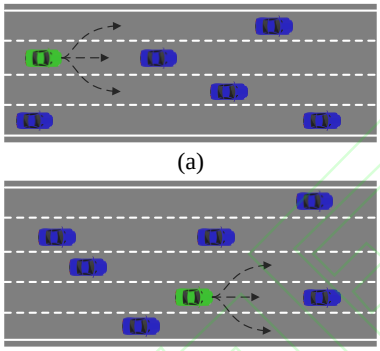
2.2　实验参数设置

为了充分仿真高速路场景的设定，定义场景中所有车辆的车速在 90-120km/h 之间，本车的初始速度为 90km/h。每个仿真周期为 20s，在仿真周期内没有发生碰撞且顺利到达指定地点即为成功。每个仿真周期回合的终止条件为：(1)车辆碰撞；(2)

车辆驶离道路；(3)仿真周期达到 20s。

实验研究了高速环境中自动驾驶车辆的多任务决策问题。具体来说，定义多车道高速公路场景和多辆具有不同驾驶风格和意图的环境自动驾驶车辆从前方不同的方向和位置随机出现。本车在理解其他车辆意图后本车需要完成左换道、减速、加速、右换道和保持当前状态等多个任务。本文研究的场景如图 5 所示，仿真场景设定为单向车道，车道数量为 4 和 5，车道宽为 3.75m，其中绿车为本车，蓝色车为环境车辆。

多驾驶员智能体分别完成多个驾驶任务其含义如表 1 所示。与人类驾驶员类似，在第一次驾驶前已经积累了一部分经验，所以 KDM 给定初始 10 回合的经验，这些经验来自有经验的驾驶员，避免在学习初期出现无意义的碰撞等行为。



(a)

(b)

图 5　多任务决策的高速场景。(a)四车道，(b)五车道

Fig.5　Highway scenario of multi-task decision-making. (a) four lanes, (b) five lanes

表 1　多驾驶员智能体含义

Tab.1　Meaning of multi-tasking agent

序号	名称	含义
1	Line-Left	转向左车道
2	Line-Right	转向右车道
3	Idle	保持当前状态
4	Faster	加速
5	Slower	减速

LLM 参数设置如表 2 所示，其中 Top-k 限制模型只考虑几个概率最大的预测结果，避免不合适的输出。Top-p 用于控制模型生成文本的概率分布平衡生成文本的准确性和多样性。Temperature 用于控制生成文本的随机性，值较高会使模型更加随机地选择词汇，值较低的会使模型更倾向选择高频词汇，调整 Temperature 值可以平衡生成决策解释的相关性。

表 2　LLM 参数设置

Tab.2　LLM parameter Settings

序号	参数	取值	范围
1	Top-k	3	[1,10]
2	Top-p	0.75	(0,1]
3	Temperature	1	(0,1]

2.3 车辆运动学建模

由知识驱动模型输出的自动驾驶动作通过闭环控制器转换为低级转向和加减速信号。车辆位置控制如式(7)和(8)所示，其中 $V_{LR,r}$ 表示车辆横向速度，$B_{c,LR}$ 表示位置增益量，Δ_{LR} 是车辆相对于所在车道中心线的横向位置，$\Delta\mu_r$ 表示执行侧向速度指令的行驶方向变化，V 表示车辆速度。

$$V_{LR,r} = -B_{c,LR} \cdot \Delta_{LR} \tag{7}$$

$$\Delta\mu_r = \arcsin\left(V_{LR,r}/V\right) \tag{8}$$

车辆行驶方向控制如式(9)-(11)所示，其中，μ_L 为车道航向，μ_r 为跟随车道航向和位置的目标航向，μ_r^1 为偏航率指令，α 为前轮角度控制，用作转向指令，$B_{c,\mu}$ 为航向控制增益量，d 表示车辆质心与前轴的距离。

$$\mu_r = \mu_L + \Delta\mu_r \tag{9}$$

$$\mu_r^1 = B_{c,\mu}\left(\mu_r - \mu\right) \tag{10}$$

$$\alpha = \arcsin\left(0.5\mu_r^1 d/V\right) \tag{11}$$

车辆运动学模型参考自动驾驶运动学自行车模型[19-20]由式(12)确定，其中(x,y)是车辆位置，μ 是航向，a 是加速度指令，η 是质心侧滑角。

$$\begin{cases} \dot{x} = V\cos(\mu+\eta) \\ \dot{y} = V\sin(\mu+\eta) \\ \dot{V} = a \\ \dot{\mu} = \left(V\cdot\sin\eta\right)/d \\ \eta = \tan^{-1}(1/2\tan\alpha) \end{cases} \tag{12}$$

除了本车的运动模型，还需要对环境车辆的运动学建模[21-22]。纵向控制的车辆加速度 a_n 如式(13)-(15)所式，其中 a_{add} 表示加速项，a_{de} 表示制动

项， a_{max} 表示最大加速度， V_{exp} 是期望速度，

$$a_n = a_{add} - a_{de} \tag{13}$$

$$a_{add} = a_{max}\left(1-\left(\frac{V}{V_{exp}}\right)^4\right) \tag{14}$$

$$a_{de} = a_{max}\left(\frac{d_{exp}}{\Delta x}\right)^2 \tag{15}$$

期望距离 $d_{exp} \in [50,100]$ 如式(16)所示，其中 d_0 表示最小安全距离，*Dis* 表示期望安全时距，a_{sub} 表示期望减速度。

$$d_{exp} = d_0 + \max\left(0, V\cdot t_s + \frac{V\Delta V}{2\sqrt{a_{\max}a_{sub}}}\right) \tag{16}$$

横向控制的环境车辆加速度 $\tilde{a}_n$ 如式(17)所示，其中 $a_{\text{sub-safe}}$ 最大安全减速度，$\tilde{a}_n$ 为换道后获得的加速度。a_{veh} 为换道车辆加速度，表示换道激进程度，λ_a 为换道决策阈值。

$$\tilde{a}_n > -a_{\text{sub-safe}} \tag{17}$$

$$\Delta a = \tilde{a}_{veh} - a_{veh} + \sigma > \lambda_a \tag{18}$$

2.4 实验条件设置

实验选择规则驱动决策模型(Rule-driven model, RDM)[7], 深度强化学习决策模型(Deep Reinforcement learning model, DRLM)[22]与KDM进行对比试验。设定两组实验，4 车道和 5 车道，分别设置 50 回合统计不同方法在两种车道的驾驶行为操作数量。为了模拟不同车流量的高速场景，设定每个仿真周期内随机生成的环境车辆 4 车道为 20 辆，5 车道为 25 辆，设置环境车辆不同的驾驶激进程度 σ，激进程度包括速度、急加速、急刹车和频繁变道。环境车辆均采用 RDM 方法控制，车辆参数设置如表 3 所示。

表 3　运动学参数设置

Tab.3　Kinematic parameters setting

控制	参数设置	四车道	五车道
纵向	a_{max}	20Km/h^2	21km/h^2
	t_s	1.5s	2s
	a_{sub}	-17Km/h^2	-17km/h^2
	d_0	15	20
横向	σ	0.1	0.05
	λ_a	0.2	0.2

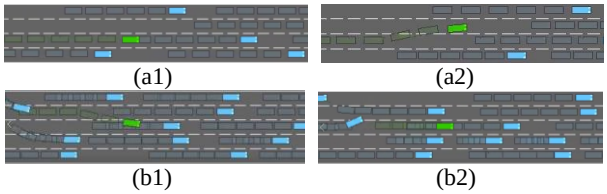
2.5 实验结果与分析

2.5.1 决策过程分析

KDM 提供当前行为、驾驶规则和注意事项等信息，并采用多步推理的策略，通过思考、行动和观察的循环来感知和分析环境信息。基于上述信息，KDM 在 Highway-Env 中进行决策和控制车辆，形成闭环驾驶系统。

DRLM 只关注最终奖励的实现，忽略中间步骤，这使得它们经常采取非常规的行动，比如减速以落后于其他车辆，然后在开阔的道路上行驶以避免碰撞，造成交通堵塞。RDM 通过优化目标函数进行决策，会在确保安全的同时寻求最大的效率，从而追求更加激进的行为，导致碰撞。KDM 会在驾驶时评估其行为的潜在后果，并权衡利弊，做出最合理的决定。如图 6(a1)所示，由于碰撞的严重惩罚 DRLM 学习了一种策略，为防止碰撞，它会在开始时减速，拉大与前车距离，然后突然加速，DRLM 经常做出类似的行为。

RDM 通过优化目标函数决策，忽略函数中未定义的部分。如图 6(a2)所示，RDM 会出现多次变道行为，以达到较高的驾驶效率，从而增加碰撞的风险。除此以外，RDM 出现了周围没有环境车辆时进行无意义变道的情况，因为对于 RDM，在保证安全的前提下，变道和保持速度只涉及状态转换，在目标函数中具有同等的优先级，只要不发生碰撞，将随机选择其中一个动作执行。



(a1)　(a2)

(b1)　(b2)

图 6　决策过程

Fig.6　Decision process

KDM 检查每个可用操作的安全性。如图(6)(b1)和(b2)所示，加速可能会导致与前车发生潜在碰撞，同时保持速度安全。当向左变道时，KDM 首先确定哪辆车将受到该动作的影响，然后了解到向右变

道是安全的。在这种情况下，KDM 已经检查了每个动作，并做出了改变到右侧车道的最终决定。图(6)(b2)尽管减速动作是相对安全的，但保持车速是一个更好的动作，因为它为本车提供了更多的灵活性，当前车道在效率和安全性之间提供了更好的平衡，考虑到右前方车的速度更快，这个决策为后续决策带来了更好的性能。

2.5.2 知识驱动模型测试分析

由表 4 可知，三种方法的驾驶行为决策数量相近，而保持速度行为最多，与车辆在高速公路上实际行驶情况相匹配，舒适性更高。KDM 可以智能地在车道保持、加速、减速和变道之间切换，以最大化性能。

表 5 为不同方法的碰撞次数、决策成功率和车辆平均车速。DRLM 提高了决策成功率，但车辆平均速度下降进一步导致交通流量减小。在规定范围内的高车速不仅显示了自动驾驶系统在处理交通流畅性方面的出色表现，还说明它能够有效地应对交通拥堵，从而使车辆行驶更顺畅，这也可以反映出自动驾驶系统在路线规划和行为决策方面的高效性。通过选择更为流畅的路线和优秀的驾驶行为，决策模块能够提升车辆的平均速度。

KDM 积累 40 回合的驾驶经验，在 4 车道就取得了 88%的成功率，与人类驾驶员学习驾驶过程类似，由于驾驶经验较少，高速环境中的车况和路况未能完全熟悉和掌握，决策成功率略低于 RDM 和 DRLM，当驾驶经验积累到 90 回合成功率提升到 98%，在三种方法中最高，RDM 决策成功率最低。与 RDM 和 DRLM 模型成功率相比，KDM 在 4 车道和 5 车道分别提高了 7%、4%和 5%和 4%，车辆平均车速也高于 RDM 和 DRLM。

表 4　驾驶行为数量统计
Tab.4　Statistics on the number of driving behaviors

方法	Line-Left	Line-Right	Idle	Faster	Slower
RDM	985	1002	1785	123	74
DRLM	785	685	2033	141	35
KDM[2]	877	943	1943	104	27

表 5　4 车道和 5 车道决策数据
Tab.5　4 and 5-lanes decision data

车道数	方法	碰撞次数	成功率	平均速度
4 车道	RDM	9	91%	105.5km/h
	DRLM	6	94%	103.1km/h
	KDM[1]	12	88%	104.6km/h
	KDM[2]	2	98%	106.1km/h
5 车道	RDM	8	92%	107.7km/h
	DRLM	7	93%	105.2km/h
	KDM[2]	3	97%	108.8km/h

注：KDM[1] 表示积累 40 回合经验，KDM[2] 表示积累 90 回合经验。

2.5.3 泛化能力测试分析

高速公路上不同车道的交通流量和车速存在较大差异，车道变化频繁，驾驶模式也各异。车辆紧急刹车、交通堵塞、车祸等可能随时发生。验证模型在不同车道数量和不同车流量的场景泛化能力可以确保系统(1)能够及时做出正确的应对措施，避免事故，(2)能够适应车道变化和各种车辆行为，从而更好地应对复杂的高速公路交通情况，(3)能够在各种交通流量和车速条件下都能够安全驾驶。

为了进一步验证模型的泛化性，采用 RDM、DRLM 和 KDM 各占 1/3 的环境车辆决策方法，以模拟不同的驾驶风格。采用 3 车道和更大的车辆密度进行泛化测试，参数设置与 2.4 中 4 车道场景设置相同，由于车道数量减少，车辆密度进一步增加，环境车的不确定性行为增大。如表 6 所示，由于车辆密度增加，三种方法碰撞次数与 4 车道相比均小幅度增加。与 DRLM 和 RDM 相比，积累 90 回合经验的 KDM 决策成功率和车辆平均车速均较高，可以有效提高车辆行驶的安全性和效率。仿真实验结果表明，KDM 在一个高速场景中积累的驾驶经验可以推广到另一个高速场景中，具备良好的泛化能力。

表 6　3 车道决策数据
Tab.6　3 lanes decision data

方法	碰撞次数	成功率	平均速度
RDM	13	91%	98.7km/h
DRLM	11	94%	96.4km/h
KDM[2]	4	94%	100.2km/h

2.5.4 可解释性分析

决策模块根据之前遇到的类似驾驶情况的推理过程和考虑来做出决策并给出解释。与 DRLM 和 RDM 的方法不同，KDM 不仅解释场景和行动，还利用知识优化决策过程。如图 7 所示，车辆在决策过程中会描述做出动作的原因，DRLM 和 RDM 方法缺乏常识、解释场景以及权衡利弊的能力。KDM 可以解释每个动作的后果，通过提示信息以知识为导向，KDM 能够做出更像驾驶员的决策，实现高级别的自动驾驶。



图 7　推理解释过程

Fig.7　Inferential interpretive process

3　结论

知识驱动的自动驾驶是一种新范式，有望突破当前自动驾驶决策技术的瓶颈，展示出了优秀的交通场景的理解能力和可持续学习能力，可以提高自动驾驶系统的安全性、可解释性和泛化能力。向知识驱动的自动驾驶的转变反映了技术发展的关键演变，强调场景理解和安全决策。将注意力机制、LLM 和向量数据库检索技术进行集成有助于与驾驶环境进行更深入、更全面的理解。作为一项初步工作只涉及 LLM 在闭环驾驶中的潜力表面来强调采用这项技术的优势，而不是将 LLM 直接作为用作驾驶智能体。在未来研究中，我们将通过微调和模型轻量化技术进一步完善知识驱动模型在城市和乡村等场景中的应用。

参考文献：

[1] 王若萱，吴建平.自动驾驶汽车感知系统仿真的研究及应用综述[J].系统仿真学报,2022,34(12):2507-2521.
Wang Ruoxuan, Wu Jianping. Overview of Research and Application on Autonomous Vehicle Oriented Perception System Simulation[J]. Journal of System Simulation, 2022,34(12):2507-2521.

[2] 郭延永,刘佩,袁泉等.网联自动驾驶车辆道路交通安全研究综述[J].交通运输工程学报,2023,23(05):19-38.
Guo Yanyong, Liu Pei, Yuan Quan. Review on research of road traffic safety of connected and automated vehicles[J]. Journal of Traffic and Transportation Engineering, 2023,23(05):19-38.

[3] 高镇海,郑程元,赵睿.真实与虚拟场景下自动驾驶车辆的主动安全性验证与确认研究综述[J/OL].吉林大学学报(工学版):1-19[2024-01-02].
Gao Zhenhai, Zheng Chengyuan, Zhao Rui.Review of active safety verification and validation for autonomous vehicles in real and virtual scenarios[J/OL]. Journal of Jilin University (Engineering and Technology Edition): 1-19[2024-01-02].

[4] 吕彦直,魏超,何元浩.基于 GCN 和 CIL 的端到端自动驾驶换道方法[J].汽车工程,2023,45(12):2310-2317.
Lv Yanzhi, Wei Chao, He Yuanhao. An End-to-End Lane Change Method for Autonomous Driving Based on GCN and CIL[J]. Automotive Engineering, 2023,45(12):2310-2317.

[5] 李晓豪,郑海斌,王雪柯等.基于改进交叉熵的模仿学习鲁棒性增强方法[J/OL].控制与决策:1-9[2024-01-02].
Li Xiaohao, Zheng Haibin,Wang Xueke. Imitation Learning Robustness Enhancement Based on Modified Cross Entropy[J/OL]. Control and Decision: 1-9[2024-

01-02].

[6] 李传耀,张帆,王涛.基于深度强化学习的道路交叉口生态驾驶策略研究[J/OL].交通运输系统工程与信息:1-16[2024-01-02].
Li Chuanyao, Zhang Fan, Wang Tao. Research on Eco-Driving Strategy for Road Intersections Based on Deep Reinforcement Learning[J/OL]. Journal of Transportation Systems Engineering and Information Technology: 1-16[2024-01-02].

[7] 熊璐,贾通,陈君毅等.基于有限状态机的预期功能安全危害识别方法[J].同济大学学报(自然科学版),2023,51(04):616-622.
Xiong Lu, Jia Tong, Chen Junyi. Hazard Identification Method for Safety of the Intended Functionality Based on Finite State Machine[J]. Journal of Tongji University (Natural Science) ,2023,51(04):616-622.

[8] 傅明建,郭福强.基于深度强化学习的无信号灯路口决策研究[J/OL].计算机工程:1-10[2024-01-02].
Fu Mingjian, Guo Fuqiang. Research on Decision making of Intersection without Traffic Lights Based on Deep reinforcement learning[J/OL]. Computer Engineering:1-10[2024-01-02].

[9] Xiao Y, Codevilla F, Gurram A. Multimodal End-to-end Autonomous driving[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 23(1): 537-547.

[10] 高振海,闫相同,高菲.基于逆向强化学习的纵向自动驾驶决策方法[J].汽车工程,2022,44(07):969-975.
Gao Zhenhai, Yan Xiangtong, Gao Fei. A Decision-making Method for Longitudinal Autonomous Driving Based on Inverse Reinforcement Learning[J]. Automotive Engineering,2022,44(07):969-975.

[11] 林歆悠,叶卓明,周斌豪.基于 DQN 强化学习的自动驾驶转向控制策略[J].机械工程学报,2023,59(16):315-324.
Lin Xinyou, Ye Zhuoming, Zhou Binhao. DQN Reinforcement Learning-based Steering Control Strategy for Autonomous Driving[J]. Journal of Mechanical Engineering,2023,59(16):315-324.

[12] Alayrac J B, Donahue J, Luc P. Flamingo: a visual language model for few-shot learning[J]. Advances in Neural Information Processing Systems(S1049-5258), 2022, 35: 23716-23736.

[13] 中国科技部.中国人工智能大模型地图研究报告[R].2023.5.28.
Ministry of Science and Technology of China. Research Report of China Artificial Intelligence Large Model Map[R]. 2023.5.28.

[14] 苏炯铭,罗俊仁,陈少飞.智能博弈决策策略求解新视角实证分析[J/OL].系统仿真学报:1-13[2024-01-02].
Su Jiongming, Luo Junren, Chen Shaofei. Game-Theoretic Decision-Making an Empirical Analysis of New Perspectives for Strategy Solving in Intelligent. Journal of System Simulation:1-13[2024-01-02].

[15] Lin B Y, Huang C, Liu Q. On Grounded Planning for Embodied Tasks with Language Models[C]//Proceedings of the AAAI Conference on Artificial Intelligence(S 2159-5399). 2023, 37(11): 13192-13200.

[16] Yang A, Nagrani A, Seo P H. Vid2seq: Large-scale Pretraining of a Visual Language Model for Dense Video Captioning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (S1063-6919). 2023: 10714-10726.

[17] 罗飞,崔滨,辛小江等.大语言模型嵌入图书馆知识服务的风险范式与管控策略[J].图书与情报,2023(03):99-106.
Luo Fei, Cui Bin, Xin Xiaojiang.The Risk Paradigm and Management Strategies of Embedding Big Language Model into Library Knowledce Services[J]. Library & Information, 2023(03):99-106.

[18] Liu C M, Fu S Y. Effective protocols for kNN search on broadcast multi-dimensional index trees[J]. Information Systems[0306-4379], 2008, 33(1): 18-35.

[19] Nie X, Liang Y, Ohkura K. Autonomous highway driving using reinforcement learning with safety check system based on time-to-collision[J]. Artificial Life and Robotics(S1433-5298), 2023, 28(1): 158-165.

[20] Kong J, Pfeiffer M, Schildbach G. Kinematic and dynamic vehicle models for autonomous driving control design [C]// 2015 IEEE Intell Vehi Symp (IV), Seoul, Korea. 2015: 1094-1099.

[21] 李伟东,马草原,史浩.基于分层强化学习的自动驾驶决策控制算法[J/OL].吉林大学学报(工学版):1-8[2024-01-10].
An automatic driving decision control algorithm based on hierarchical reinforcement learning[J/OL]. Journal of Jilin University(Engineering and Technology Edition) :1 -8[2024-01-10].

[22] 张新锋,吴琳.基于集成深度强化学习的自动驾驶车辆行为决策模型[J].汽车安全与节能学报,2023,14(04):472-479.
Zhang Xinfeng, Wu Lin. Behavior decision-making mode for autonomous vehicles based on an ensemble deep reinforcement learning[J]. Journal of Automotive Safety and Energy,2023,14(04):472-479.