

计算机工程
Computer Engineering
ISSN 1000-3428,CN 31-1289/TP

《计算机工程》网络首发论文

题目：多智能体博弈环境下的大语言模型协同决策研究
作者：余滔，董军
DOI：10.19678/j.issn.1000-3428.0070301
网络首发日期：2025-01-10
引用格式：余滔，董军．多智能体博弈环境下的大语言模型协同决策研究[J/OL]．计算机工程. https://doi.org/10.19678/j.issn.1000-3428.0070301



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2025-01-10 17:56:12　网络首发地址：https://link.cnki.net/urlid/31.1289.tp.20250110.1638.002

多智能体博弈环境下的大语言模型协同决策研究

余滔*，董军

(华北电力大学 经济与管理学院，北京 100096；)

摘　要：在多智能体博弈仿真中，大语言模型的能力已经被广泛研究，但其在模糊任务目标或不确定性环境中引导多智能体合作的决策能力往往出现“失灵”现象。针对这一问题，提出了一种基于分布式贝叶斯推断的多层级协同决策框架。该框架基于分布式贝叶斯推断方法，集成了“决策—互评—监管”三大功能模块，利用多个大语言模型进行协同决策，并在空间囚徒困境博弈中进行了实验验证。实验结果表明，该框架有效克服了大语言模型在模糊任务环境下的决策瓶颈，成功促进了多智能体合作行为的涌现。此外，通过对不同实验场景下模型决策能力的量化评估，发现模型的决策误差与模型规模不呈线性关系。在模糊任务指令下，LLAMA3（70B）模型的决策误差较 LLAMA3（8B）模型高出 16.6%，较 LLAMA2（7B）模型高出 7.2%，表明在更复杂环境中，单纯依赖模型规模的扩大未能显著提升决策性能。相反，大语言模型协同决策在提升决策一致性和有效性方面显示出显著优势。这些结果揭示了多模型协同在复杂决策环境中的关键作用，并为未来在不确定性任务下的智能体系统设计提供了重要参考。

关键词：大语言模型；多智能体仿真；空间囚徒困境博弈；分布式贝叶斯推断；多层级协同决策框架

DOI：10.19678/j.issn.1000-3428.0070301

Research on Collaborative Decision-Making of Large Language Models in Multi-Agent Game Environments

Yu Tao*, Dong Jun

(School of Economics and Management, North China Electric Power University, Beijing 100096;)

Abstract: The capabilities of large language models (LLMs) in multi-agent game simulations have been widely studied, but their ability to guide cooperative decision-making among agents often fails in environments with fuzzy task objectives or uncertainty. To address this issue, a multi-level collaborative decision-making framework based on distributed Bayesian inference is proposed. This framework integrates three functional modules—decision-making, peer review, and supervision—utilizing multiple LLMs for collaborative decision-making. The framework is validated through experiments in spatial prisoner’s dilemma games. The results demonstrate that this framework effectively overcomes the decision-making bottlenecks of LLMs in fuzzy task environments, successfully promoting the emergence of cooperative behavior among agents. Additionally, a quantitative evaluation of decision-making capabilities across different experimental scenarios reveals that decision errors do not scale linearly with model size. Under fuzzy task instructions, the decision error of the LLAMA3 (70B) model is 16.6% higher than that of the LLAMA3 (8B) model and 7.2% higher than that of the LLAMA2 (7B) model, indicating that simply increasing model size does not significantly improve decision-making performance in more complex environments. In contrast, the collaborative decision-making of LLMs shows significant advantages in enhancing decision consistency and effectiveness. These findings highlight the crucial role of multi-model collaboration in complex decision environments and provide valuable insights for the design of intelligent agent systems in uncertain tasks.

Keywords: Large Language Models; Multi-Agent Simulation; Spatial Prisoner's Dilemma Game; Distributed Bayesian Inference; Multi-Level Collaborative Decision-Making Framework

0　引言

近年来，大型语言模型（Large Language Models, LLMs）如ChatGPT、LLaMa等，迅速改变了人类与人工智能的交互方式[1-3]。研究表明，这些模型已广泛应用于文本生成、摘要、翻译等领域，并展现出在复杂推理和规划任务中的巨大潜力[4]。通过大规模语料的预训练，它们具备零样本泛化能力，并可通过微调适应特定应用场景[5]。此外，大语言模型在多语言处理和跨领域任务中的表现极大提升了其自然语言理解和人机交互的实用性[6-8]。随着技术的

基金项目：国家电网科学技术项目（1400-202256459A-2-0-ZN）

通信作者 E-mail：120212106030@necpu.edu.cn

不断发展，预期它们将在更复杂的应用场景中发挥重要作用，推动各行业的变革。

现有研究已验证大语言模型在经典博弈论场景（如囚徒困境和最后通牒游戏）中的表现，展示了其模拟人类行为的潜力，为强人工智能的构建奠定了基础[9-12]。然而，在实际应用中，复杂系统问题（如群体合作与背叛、自动驾驶、网络安全合作）通常伴随高度的不确定性和模糊任务目标[9-12]。以囚徒困境博弈为例，个体需在合作与背叛间做出抉择。当大语言模型仅接收到“维持群体合作”或“减少背叛行为”等模糊指令，而缺乏明确任务目标时，往往难以制定有效策略，无法有效促进合作。这种“决策失灵”现象在AI心理学中可理解为模型未能准确掌握合作与背叛间的内在关联，未能充分认识不同博弈条件下行为选择的长期影响。而本质上，这可归因于大语言模型的“幻觉”问题，即模型在面对模糊、不完全信息时，产生错误的策略推理和判断，导致决策失效。

由于大语言模型主要依赖于上下文信息和统计关联来生成响应，当提示模糊或信息不足时，模型的决策依据往往基于不完全的推理过程，这进一步放大了模型“幻觉”，导致其在动态、多变的博弈环境中难以做出有效决策[13]。这种现象不仅反映了模型在不确定任务下的局限性，还揭示了当前大语言模型在复杂决策场景中缺乏强有力的自主推理能力，而这成为了本文研究着重解决的关键问题。

增强大语言模型的自主推理能力可从提示工程和算法优化两方面入手[14-16]。提示工程方法包括链式思维提示（CoT）和渐进提示引导（PHP）等；而算法优化则涉及自主树搜索（ATS）、图形验证等技术。虽然这两类技术能够显著提升大语言模型的推理能力，但它们往往是在预定义任务或静态环境下进行测试，面对复杂博弈环境和动态情境时其效果尚未证实。且这些技术往往伴随着较高的计算资源需求和较大的实现复杂性，尤其在大规模部署时，成本问题更加突出。相比之下，直接采用大语言模型进行协同决策，不仅减少了对复杂技术的需求，还能更加灵活地应对复杂情境，提高系统的稳定性和适应性。

博弈论为理解和评估大语言模型的决策能力提供了合理的理论基础和理想的实验环境[17]。其中，空间囚徒困境博弈模型结合了传统囚徒困境博弈和网络结构，用以研究在特定空间分布和多智能体交互环境中合作与背叛行为的演变[12,18]。在这背景下，本研究构建了一个大语言模型与多智能体仿真结合的实验架构，其关键在于检验大语言模型在复杂博弈环境中的决策能力以及在模糊任务提示下多个大语言模型协同的实际效果。本文的主要工作及重要结论如下：

1）研究设计了在复杂博弈环境下两种可比的实验场景。其中，实验1设定了明确的任务目标，即要求大语言模型促进合作行为；而实验2则未设定明确的任务目标。实验结果表明，在模糊任务目标下，大语言模型出现了明显的决策“失灵”现象，且规模较大的模型并未在此情境中有更优表现。

2）为解决模糊任务目标下大语言模型决策“失灵”问题，本研究设计并提出了一种基于分布式贝叶斯推断的多层级大语言模型协同决策框架。该框架基于分布式贝叶斯推断方法，融合了互评和监管机制以增强决策质量。并在模糊任务目标情境下（实验3）进行验证，结果显示该协同决策框架显著提升了大语言模型在模糊任务目标下的决策表现。此外，单独引入互评机制、监管机制或两者结合的协同框架也能够有效提升模型的决策能力，且三者之间并无太大效果差异。

1 相关工作

通过对现有研究进行梳理，与本文研究密切相关的文献可以分为两类：一类关注大语言模型在多智能体仿真中的应用，另一类则探讨了大语言模型协同决策问题。

1.1 大语言模型在多智能体仿真中的研究现状

多智能体仿真是研究复杂动态系统的重要工具[19-20]。目前，结合大语言模型的多智能体仿真不仅可以满足复杂系统仿真的需求，还可以通过其卓越的感知和决策能力克服传统方法的局限[21]。例如，Gao等人[21]开发了一个名为S3的社交网络仿真系统，通过集成大语言模型增强多智能体的模拟能力，使其能够复现社交网络中的人类情感、态度和互动行为。类似地，Williams等人[22]提出了一种结合大语言模型的多智能体流行病建模方法，成功模拟了人类行为在流行病传播中的表现。同时，也有少数研究致力于研究构建强博弈智能体。例如，Mao等人[23]开发了“Alympics”系统模拟框架，并通过“水资源分配调整”案例展示了在定性和定理分析博弈策略和结果方面的能力。

聚焦在交互行为仿真领域，研究集中在通过博弈论框架探讨大语言模型在模拟合作与推理行为方面的表现[24-26]。例如，Xu等人[9]探讨了大型语言模型在沟通游戏

中的应用，特别是在狼人游戏中的表现，结果表明大语言模型能有效参与策略性互动，产生信任和对抗等行为。而Suzuki等人[27]通过演化博弈模型展示了大语言模型如何通过人格特征模拟人类行为的演化，揭示了基于高阶人格表征的合作行为如何随时间演进。此外，Guo[11]探索了大语言模型在最后通牒游戏和囚徒困境中的表现，表明了其在模拟公平交易和条件合作行为方面的潜力。另外一方面，Phelps等人[28]进一步研究了GPT-3.5在多轮囚徒困境中的表现，发现尽管大型语言模型能够反映利他或自利行为，但在动态互动和条件性回报策略的适应性上仍存在局限。此外，Akata等人[25]研究表明，在有限次重复游戏中，如囚徒困境和性别之战，虽然大语言模型能够追求自身利益，但在需要协调合作的场景中表现不佳。这些研究共同揭示了大语言模型在模拟复杂社会互动中的局限性，并强调了未来在AI与人类价值对齐及社会互动适应性提升方面的研究需求。

1.2 大语言模型协同决策研究现状

除了在多智能体仿真中的应用外，大语言模型协同决策也引起了广泛关注。首先，Lin等[29]通过评估在多智能体环境中大语言模型的能力，验证了大语言模型协同决策的发展潜力。而Zhang等[10]研究则探讨了不同协作策略对大型语言模型性能的影响。结果显示，那些倾向于促进讨论的策略比那些主要基于记忆和反思的策略表现得更为出色。

除了检验各个大语言模型协同决策能力之外，如何构建更加有效的协同决策机制也是目前研究的重点方向。其中，Xiong等[30]通过构建正式辩论框架（FORD）评估了大语言模型协作表现，结果表明正式辩论框架能促进多个大语言模型达成共识，从而做出更有决策。此外，Xu等[31]引入了一种模拟学术同行评审过程的协作框架，让多个模型相互纠正以提高推理任务的准确性。结果显示，与现有方法相比，这种协作方式在多个推理任务中表现更优。同时，Zhang等[32]则采用了演员-评论员（Actor-Critic）框架，提出了一种新的方案来增强大语言模型在大规模多智能体环境中的协调和决策能力。这些研究为开发更智能、更高效的基于大语言模型的多智能体系统提供了坚实的理论基础，并展示了大语言模型协同决策的广阔应用前景。

2 本文模型

2.1 大语言模型

本研究选择了 Meta 公司发布的 LLAMA 开源系列大语言模型[33]作为本研究的实验模型。其中，表 1 详细展示了 LLAMA 系列语言模型与其它语言模型的性能比较。

在六个不同的基准测试中，LLAMA系列模型都有较为出色的表现，其中值得注意的是尽管GPT-3和PaLM具有更多的参数，但LLAMA系列模型在许多情况下的性能与其不相上下甚至更为出色，因此采用LLAMA系列模型作为本文的实验模型具有一定的代表性和可比性。

表 1 大语言模型性能比较结果

Table 1: Large Language Model Performance Comparison Results

模型	GLUE	SQuAD	HumanEval	APPS	MATH	StrategyQA
LLAMA3 (70B)	92.5	94.2	78.6	62.3	89.1	71.8
LLAMA3 (8B)	90.7	92.1	72.4	58.9	85.6	68.2
GPT-3 (175B)	89.4	92.5	65.7	51.2	79.3	62.1
PaLM (540B)	91.2	93.8	70.1	56.8	83.7	66.4
LLAMA2 (7B)	88.3	90.5	68.9	53.7	81.2	63.8

2.2 复杂网络演化博弈模型

本文以NW小世界网络作为多智能体仿真的交互环境，此网络模型通过保持较高的节点聚类系数和缩短路径长度，有效地再现了现实社会网络中的小世界现象[34]。在该网络中包括50个节点，每个节点初始连接4个邻近节点，并设置重连概率为0.3。网络的每个节点代表一个智能体，这些智能体的行为策略在合作与背叛之间随机选择，用以模拟社会互动中个体的行为动态[35-36]。此外，采用了囚徒困境博弈模型作为节点间互动的基本框架，支付矩阵如表2所示，反映了不同策略组合下的收益情况。

表 2 囚徒困境博弈的收益矩阵

Table 2: Prisoner's Dilemma Game Payoff Matrix

甲 / 乙	合作	背叛
合作	R	S
背叛	T	P

其中，R、S、T、P 为选择相应策略时获得的收益大小。R 表示当双方都选择合作时，每个个体获得的奖励收益；S 表示一方选择合作，而另外一方背叛时，选择合作的一方获得的收益；T 表示当一方选择背叛，

另外一方选择合作时，选择背叛一方获得的收益；P 表示当双方都选择背叛时，每个个体获得的收益。根据经典的囚徒困境逻辑，当收益满足 $T>R>P>S$，以及 $2R\geq T+S$ 的条件时，囚徒困境博弈现象即会显现。因此，参数设定为 T = 1.5；R = 1；P =0.5；S =0。

而多智能体间的互动行为遵循 Fermi 动力学，即允许节点通过比较自身与邻居节点的策略及相应的收益来决定是否变更策略[35]。该动力学过程遵循以下公式：

$$P\left(s_i \to s_j\right)=\frac{1}{1+e^{\frac{\left(U_i-U_j\right)}{k}}} \tag{1}$$

其中，s_i 和 s_j 分别表示节点 i 和节点 j 的当前策略，U_i 和 U_j 分别表示节点 i 和节点 j 在当前策略下的收益，而 k 是噪声因子，用于控制策略更新的随机性，本文中设 $k=0.1$。

2.3 基于分布式贝叶斯推断的多层级大语言模型协同决策框架

2.3.1 大语言模型协同决策框架

本研究构建了一个基于分布式贝叶斯推断的多层级大语言模型协同决策框架。该框架包括决策层、协作层以及反馈回路。

在此框架中，决策层作为核心模块，由一个大语言模型担任，负责解析和处理高复杂度的决策任务。首先，分布式贝叶斯推断算法根据当前的合作比例和奖惩策略信息，计算出全局后验分布，以预测下一个时间步的合作趋势。随后，这些预测结果将被传递给大语言模型。基于这些后验数据和其他反馈信息，该模型生成相应的奖惩决策。

而协作层包含评价者和监管者两个角色，均由大语言模型分别担任。评价者在每轮博弈后基于合作比率等信息进行评估，生成优化策略建议并反馈给决策层。监管者则监控多智能体系统的行为是否符合预定目标，在合作比例显著下降时，触发监管机制，本文设定为合作者比例为30%，此时监管者会提示决策者调整奖惩策略，以保证系统的整体合作水平。反馈回路是框架的闭环部分，这一部分确保了在每一轮博弈结束后，将所有相关的决策数据、行为反馈和推断结果重新输入到决策层中，以便大语言模型根据最新信息进行策略优化。

在本框架中，采用提示工程技术来明确大语言模型的行为。通过构建特定的提示，每个模型将根据其角色和任务执行相应的操作。其提示工程如表3所示。

表 3 协同决策框架提示工程

Table 3: **Prompt Engineering for Collaborative Decision-Making Framework Table**

模块	功能	提示工程
决策层	决策模型	你现在是一个博弈游戏决策者，根据现有数据，根据合作比例、贝叶斯推断数据等，分析游戏状态并生成奖惩策略。
协作层	监管者模型	你现在是一个博弈游戏监管者，根据现有数据以及决策模型决策结果，分析游戏状态并生成奖惩策略。
	互评者模型	你现在是一个博弈游戏评价者，根据现有数据以及决策模型决策结果进行评价分析，分析游戏状态并生成奖惩策略。

2.3.2 分布式贝叶斯推断方法

分布式贝叶斯推断是一种用于处理大规模数据和复杂系统中不确定性问题的推断方法[35]。它将传统贝叶斯推断的计算任务分解并通过局部贝叶斯推断，最终获得全局的推断结果。本文通过分布式贝叶斯推断方法，对每轮决策后的合作率进行估计，并将其信息传递给大语言模型进行决策，从而辅助大语言模型的策略实施。分布式贝叶斯推断方法具体实现如下。

步骤1：计算先验分布 $P(\theta)$。$P(\theta)$ 反映了在没有观察数据之前对参数 θ 的信念。如果假设参数 θ 是一个维度为 p 的向量，并使用高斯分布作为先验分布，则有：

$$P(\theta)=\mathcal{N}(\mu_0,\Sigma_0) \tag{2}$$

且 μ_0 是先验均值，有：

$$\mu_0=\begin{pmatrix}\mu_{0,1}\\ \mu_{0,2}\\ \vdots\\ \mu_{0,p}\end{pmatrix} \tag{3}$$

而 Σ_0 是一个 $p\times p$ 协方差矩阵，可表示为：

$$\Sigma_0=\begin{pmatrix}\sigma_{0,11} & \sigma_{0,12} & \cdots & \sigma_{0,1p}\\ \sigma_{0,21} & \sigma_{0,22} & \cdots & \sigma_{0,2p}\\ \vdots & \vdots & \ddots & \vdots\\ \sigma_{0,p1} & \sigma_{0,p2} & \cdots & \sigma_{0,pp}\end{pmatrix} \quad (4)$$

由于模型中的初始合作比例为0.5左右，因此，设定参数θ为0.5。

步骤2：进行局部贝叶斯推断。首先是构建观察数据的似然函数。假设观察数据D_i是在时间序列上的观测值，在给定参数θ的情况下，观察数据的似然函数可以表示为：

$$P(D_i|\ \theta)=\prod_{j=1}^{n_i}\mathcal{N}(d_{ij}|\ \mu(\theta,t_j),\sigma^2) \quad (5)$$

其中，d_{ij}是在时间t_j的观测值，$\mu(\theta,t_j)$是由参数θ决定的均值函数，σ^2是观察噪声的方差，一般设置为0.1。

然后，根据贝叶斯公式，结合先验分布和似然函数，得到局部后验分布$P(\theta|\ D_i)$，即有：

$$P(\theta|\ D_i)=\frac{P(D_i|\ \theta)\cdot P(\theta)}{P(D_i)} \quad (6)$$

其中，$P(D_i)$是标准化常数，计算公式为：

$$P(D_i)=\int P(D_i|\ \theta)\cdot P(\theta)d\theta \quad (7)$$

步骤3：进行后验分布合并。采用Wasserstein质心方法合并后验分布，有：

$$\nu^*=\arg\min_\nu\sum_{i=1}^{k}W_2^2(\nu,P(\theta|\ D_i)) \quad (8)$$

其中，$W_2^2(\nu,P(\theta|\ D_i))$是Wasserstein距离的平方，$\nu^*$是合并后的后验分布。

步骤4：进行全局后验推断与决策。首先，在合并后的后验分布$P(\theta|\ D_1,D_2,\ldots,D_k)$基础上，通过优化获取最大后验概率估计（MAP），MAP估计考虑了先验知识和观察数据，从而得到最优的参数值。其公式如下：

$$\hat{\theta}_{\text{MAP}}=\arg\max_\theta P(\theta|\ D_1,D_2,\ldots,D_k) \quad (9)$$

接着，通过采样合并后的后验分布，计算统计量（如后验均值和方差）并将其数据传递给大语言模型进行决策和推断。

步骤5：最后，在每轮推断和决策之后，可以使用新观测数据D_{new}来更新先验分布$P_{\text{new}}(\theta)$，形成下一轮的推断基础，公式如下：

$$P_{\text{new}}(\theta)=P(\theta|\ D_{\text{new}}) \quad (10)$$

2.4 大语言模型在多智能体博弈中的应用

本研究利用大语言模型生成动态的奖惩策略，以调控智能体的行为。在博弈过程中，大语言模型通过分析当前的博弈状态，输出相应的奖励和惩罚值。具体而言，在每轮博弈开始前，上一轮博弈过程中所有智能体的合作比例、收益等信息都会传递给大语言模型。基于这些数据，观察大语言模型如何生成符合预设合作比例目标的奖惩策略。

而奖励和惩罚值的设定范围分别为0至5和-5至0，这是为了确保激励和惩罚的适度和合理性。大语言模型的决策可分为三种类型：纯奖励、纯惩罚及奖惩结合。公式如下：

$$U_i=\begin{cases}\pi_i+r & \text{if } s_i=C\\ \pi_i+p & \text{if } s_i=D\end{cases} \quad (11)$$

其中，r表示对合作的奖励，p表示对背叛的惩罚。上述奖惩机制通过对节点收益的调整，影响其策略更新过程，从而引导网络中合作行为的演化。

3 实验与评价分析

3.1 实验结果与分析

为检验大语言模型协同决策在复杂博弈环境中的实际表现。本文选择LLAMA3（70B）、（8B）以及LLAMA2（7B）三个模型进行实验，并分别设置了三组实验。

其中，实验1作为本文研究的基础实验，通过提供明确的任务目标，验证大语言模型在明确提示下的实际表现。实验2则进一步对比探讨了在模糊任务目标下大语言模型的实际表现。实验3则同样在模糊任务目标下，测试了多个协同决策框架的有效性，并提出了基于分布式贝叶斯推断的协同决策框架。

同时，为保证实验的可比性，提示工程将保持一致，且为降低大语言模型文本输出的随机性，实验中温度参数设置为0。其中实验提示工程如表4所示，协同决策框架提示词则如表3所列。

表 4 实验提示工程

Table **4: Experimental Prompt Engineering**

实验	提示工程
实验 1	你现在是一个博弈游戏决策者，根据合作比例、收益等数据，分析游戏状态并生成奖惩策略，确保群体合作行为的涌现。
实验 2	你现在是一个博弈游戏决策者，根据合作比例、收益等数据，分析游戏状态并生成奖惩策略。
实验 3	你现在是一个博弈游戏决策者，根据合作比例、收益、贝叶斯推断等数据，分析游戏状态并生成奖惩策略。

3.1.1 实验 1

在实验1中，表5展示了大语言模型在每轮博弈中的决策逻辑形式，并对关键逻辑进行了整理展示。图1则展示了每轮博弈的奖惩决策结果。

表 5 实验 1 中大语言模型决策逻辑

Table **5: Decision Logic of Large Language Models in Experiment 1**

	LLAMA3（70B）大语言模型		LLAMA3（8B）大语言模型		LLAMA2（7B）大语言模型	
博弈时间	决策逻辑	决策结果	决策逻辑	决策结果	决策逻辑	决策结果
1	根据目前的游戏状态，合作比例为 0.56。为进一步提升合作行为，将提供适度的奖励以激励更多的合作行为，并对背叛行为进行适当的惩罚。	奖励值: 5； 惩罚值: -5	根据目前的游戏状态，由于合作比例相对较低（0.52），将增加合作的奖励并进行背叛的惩罚，以激励节点进行合作。	奖励值: 4； 惩罚值: -3	当前游戏状态下，合作比例为 0.54，为进一步增强合作行为并抑制潜在的背叛行为，将实施较高的奖励以激励合作，并施加适当的惩罚。	奖励值: 5； 惩罚值: -3
2	根据目前的游戏状态，合作比例仍然维持在 0.56，为进一步促进合作比例，将继续执行奖励合作行为的策略，并适当调整惩罚措施。	奖励值: 5； 惩罚值: -3	根据目前的游戏状态，合作比例较高（0.54），将通过适度的奖励进一步提高合作比例，同样由于背叛比例较低（0.46），将通过轻微的惩罚进一步减少背叛比例。	奖励值: 4 惩罚值: -3	当前游戏状态下，合作比例提高至 0.68，为保持并加强合作，将继续执行较高的奖励策略，并通过适度的惩罚进一步降低背叛比例。	奖励值: 5； 惩罚值: -3
…	…	…	…	…	…	…
100	根据目前的游戏状态，合作比例为 1，为保持合作行为，将继续奖励合作，并实施惩罚来抑制背叛行为的出现。	奖励值: 5； 惩罚值: -5	根据目前的游戏状态，由于合作比例较高（0.92），将设置适度的合作奖励和轻微的背叛惩罚。	奖励值: 4； 惩罚值: -1	当前游戏状态下，合作比例下降至 0.4，为激励合作行为，选择维持较高的奖励值，并通过适度的惩罚来防止背叛。	奖励值: 5； 惩罚值: -3

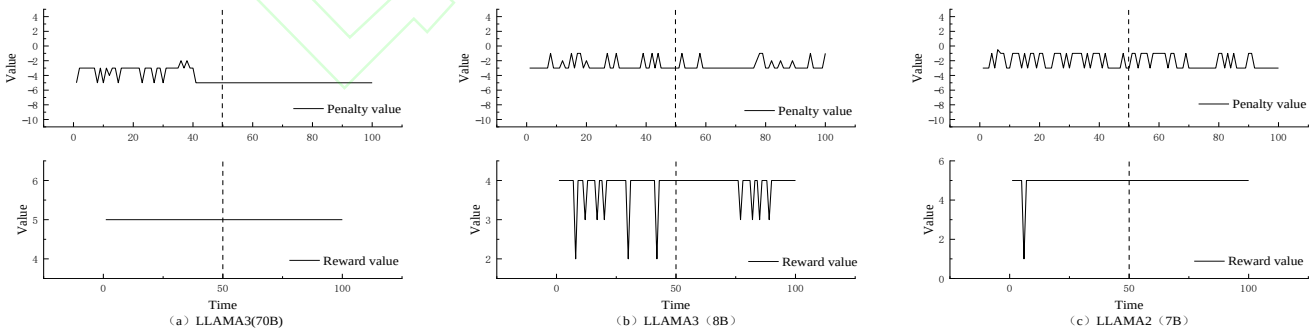


图 1 实验 1 中大语言模型决策结果

Figure 1: Decision Outcomes of Large Language Models in Experiment 1

首先，由模型的决策逻辑和结果来看，实验中的大语言模型在博弈决策过程中普遍使用了较高的奖励(奖励值为4)以及中等惩罚者(惩罚值为-3)。接着，根据图2多智能体系统的演化结果，所有的大语言模型通过奖惩组合均有效激励了系统中的合作行为，并在合作比例提升后能够继续通过适度

的奖惩机制维持合作的稳定。其中LLAMA3（70B）以及8B模型的奖惩组合机制更加有效，促进了系统合作行为的高占比。而LLAMA2（7B）模型的决策表现稍显欠缺，虽然给出了较高的奖励值，但是对背叛行为的惩罚力度不足，导致系统中的合作行为并未维持在较高水平。

因此，这一实验现象揭示，在明确的提示工程下，大语言模型在复杂的博弈环境中有较为出色的决策能力，并有一定的灵活性和适应性。具体而言，模型能够根据动态环境的反馈灵活调整奖惩策略，展现出与人类决策者在复杂情境下应对变化的相似特性。

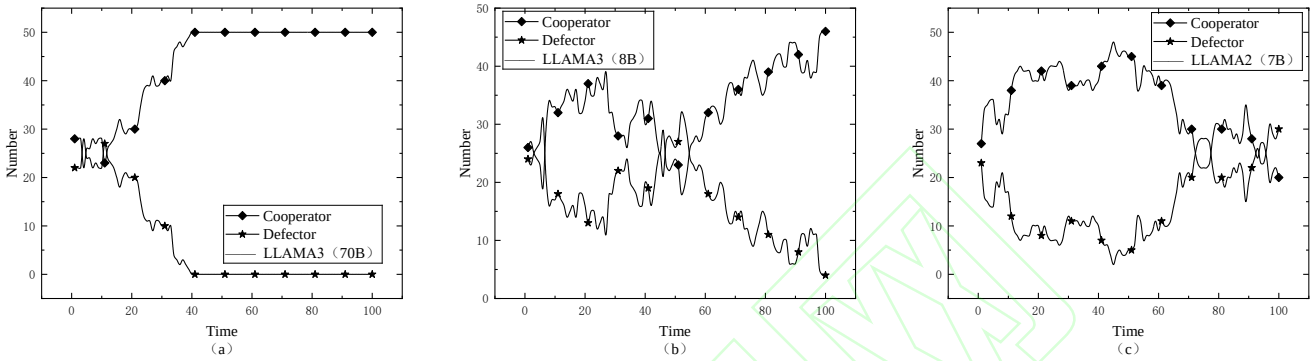


图 2 实验 1 中多智能体博弈演化图

Figure 2: Evolutionary Diagram of Multi-Agent Game in Experiment 1

3.1.2 实验 2

在实验2中，表6展示了在实验2中大语言模型在每轮博弈中的决策逻辑形式，并对关键逻辑进行了整理展示。图3则展示了实验2中每轮博弈的奖惩决策结果。

表 6 实验 2 中大语言模型决策逻辑

Table **6: Decision Logic of Large Language Models in Experiment 2**

	LLAMA3（70B）大语言模型		LLAMA3（8B）大语言模型		LLAMA2（7B）大语言模型	
博弈时间	决策逻辑	决策结果	决策逻辑	决策结果	决策逻辑	决策结果
1	根据目前的游戏状态，合作比例较低，为 0.38，背叛比例较高。因此，设定奖励值为 2，惩罚值为-3。	奖励值：2； 惩罚值：-3	根据当前的合作比例为 0.48 和背叛比例为 0.52，似乎玩家大多选择了背叛。为了促进更多的合作，将设定较高的合作奖励和较低的背叛惩罚。	奖励值：3； 惩罚值：-2	根据目前的游戏状态，合作比例为 0.34，应给予奖励，鼓励游戏者继续合作，同时由于部分游戏者选择了背叛，因此需要进行惩罚。	奖励值：2； 惩罚值：-1
…	…	…	…	…	…	…
17	根据目前的游戏状态，可以设定一个简单的决策逻辑，如果合作比例过低，将给予惩罚，否则给予奖励。因此奖励和惩罚的计算公式为： 惩罚值 = -5 * (1 –合作比例) = -5 * (1 - 0.06) = -4.7； 奖励值 = 5 * 合作比例 = 5 * 0.06 = 0.3	奖励值：0.3； 惩罚值：-4.7				
…	…	…	…	…	…	…
100	根据目前的游戏状态，合作比例为 0，因此需要对背叛行为进行惩罚，惩罚	奖励值：0； 惩罚值：-5	根据当前游戏状态，合作比例为 0，背叛比例为 1。使用上述公式计算奖励和	奖励值：0； 惩罚值：0	在当前游戏状态下，由于所有的玩家都是不合作的，所以没有玩家可以获胜，因此	奖励值：-3； 惩罚值：2

LLAMA3（70B）大语言模型	LLAMA3（8B）大语言模型	LLAMA2（7B）大语言模型
值为-5。	惩罚值: 奖励值 = (0 / 5.4) * 5 = 0 惩罚值 = -0 = 0 因此，本轮奖励值和惩罚值为 0	奖励设为-3，表示玩家失去三次机会。同时将惩罚设为2，表示玩家失去两次机会。

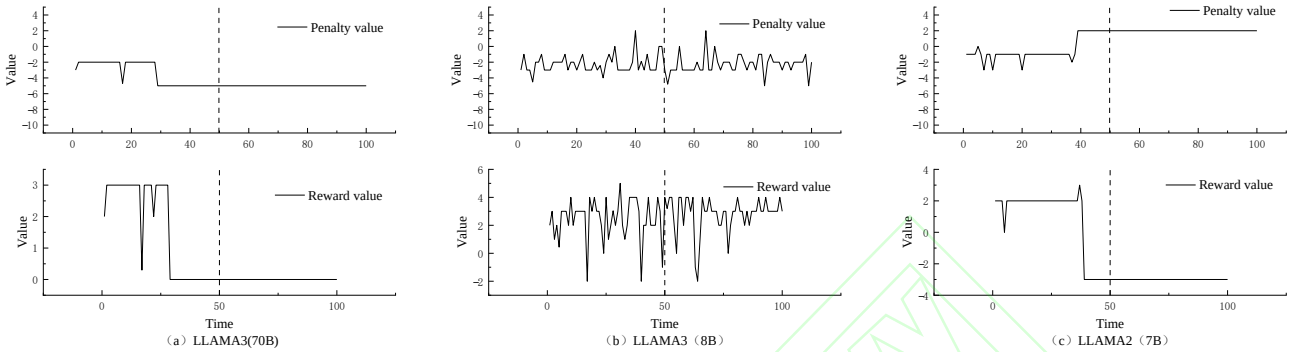


图 3 实验 2 中大语言模型决策结果

Figure 3: Decision Outcomes of Large Language Models in Experiment 2

首先，从实验2的决策逻辑以及结果来看，在无明确促进合作行为发生的指令下，各模型的奖惩决策分布较为分散。接着，根据图4智能体博弈演化结果，所有大语言模型决策过程中都未能有效促进系统合作演化。其中，LLAMA3（70B）模型的决策表现较为一致，奖惩值相对稳定。8B模型则显示出较高的波动性，且奖惩决策在不同轮次之间存在显著的变化。相比之下，LLAMA2（7B）模型的决策相对保守，且从决策逻辑中可以看出有一定的决策错误。

值得注意的是，从大语言模型的决策文本中能够发现LLAMA3（70B）以及8B模型在模糊任务目标下，尝试通过数学逻辑来设定奖惩值。通过对大语言模型中的公式进行深入分析，可以发现LLAMA3（70B）的数学逻辑是基于当前合作比例的简单线性计算，直接反映了合作比例对奖惩值的影响。而LLAMA3（8B）则是基于两种不同行为收益的加权平均计算，其本质类似于收益的期望计算，通过将将合作比例与合作收益的乘积与背叛者比例与背叛收益的乘积相加，且惩罚值的计算也遵循了同样的逻辑，从而得到奖惩值。而这两者奖惩计算逻辑均未与激励合作行为发生有直接关联。因此，这样的决策逻辑在动态调整奖惩机制时将会导致策略效果与预期存在偏差。

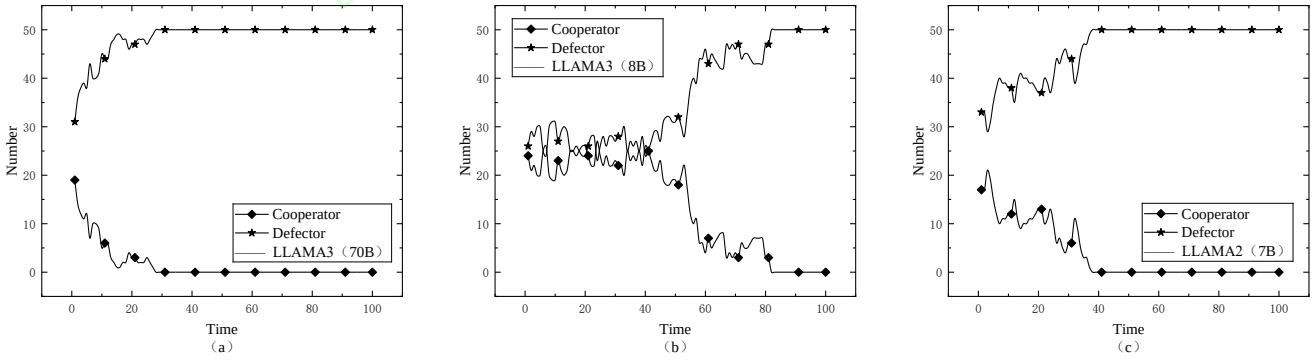


图 4 实验 2 中多智能体博弈演化图

Figure 4: Evolutionary Diagram of Multi-Agent Game in Experiment 2

实验2的结果表明，在模糊任务目标环境中，大语言模型的决策效果受到一定影响。虽然模型具备一定的调整能力，但会选择保守或者随机策略，从而无法有效解决复杂决策问题。虽然大语言模型未能做出正确的决策，但可以发现大语言模型在没有明确目标指导的情况下，展示了其自主生成决策逻辑的能力，这表现在大语言模型自行推导出数学公式以尝试对博弈环境进行合理的响应。这一行为反映了模型的高度自适应性和解决问题的能力，是其智能处理复杂任务的明显优势。然而，模型的这种自主生成的决策逻辑同时也暴露了其理解任务具体需求的局限。

因此，大语言模型在处理某些复杂问题时将面临挑战：在更加开放式的决策环境中，模型虽然能够根据数据生成复杂且合逻辑的答案，但其答案可能不完全符合人类设定的期望或实际需求。而要有效利用大语言模型处理类似任务，就必须在模型训练和策略设计阶段更精确地定义和强化目标导向，确保模型在生成决策时能够更好地理解并完成任务。

3.1.3 实验 3

在实验3中，为了避免模型参数大小带来的潜在影响，实验3都选择使用LLAMA3（8B）模型来进行仿真实验。

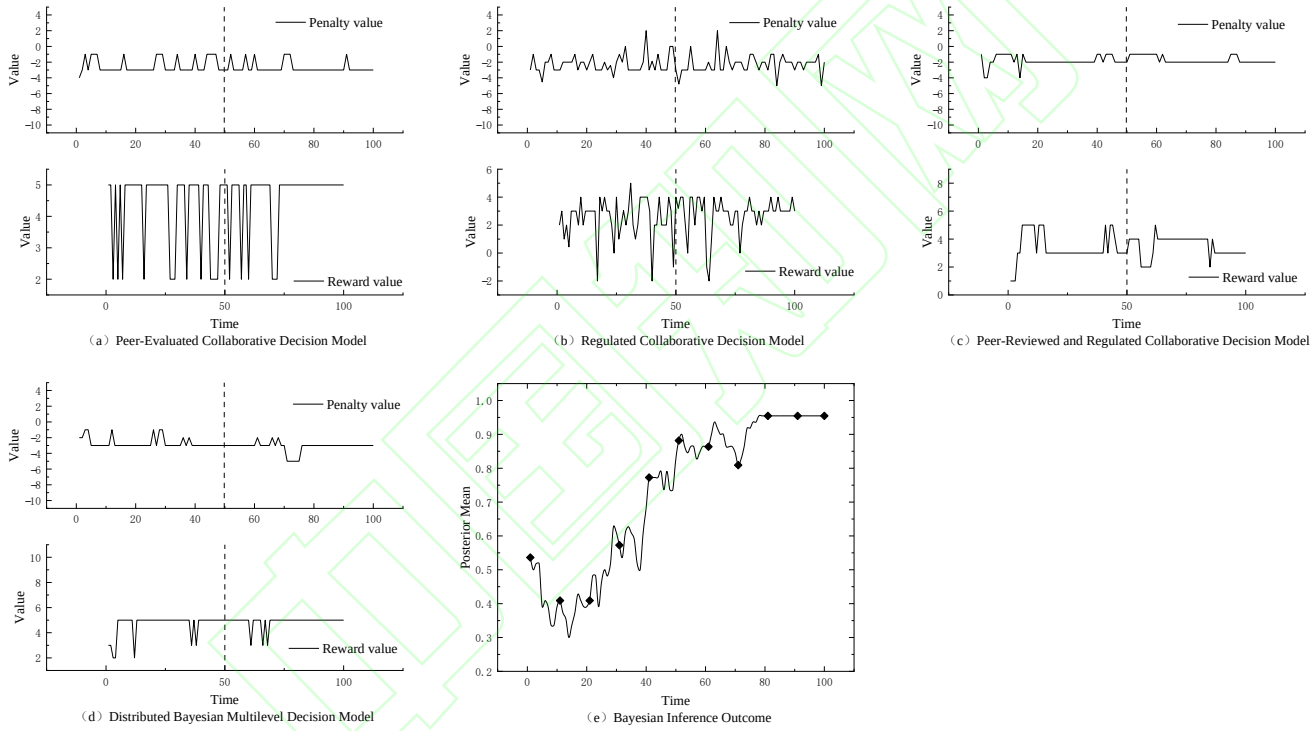
其中，表 7 详细记录了其决策思路与结果，图 5 则展示了每轮博弈中模型决策的奖惩值变化，其中图 5（e）是分布式贝叶斯推断结果，反映了估计的合作比例变化趋势。

表 7 实验 3 中大语言模型决策逻辑

Table 7: **Decision Logic of Large Language Models in Experiment 3**

	引入互评机制的协同决策框架		引入监管机制的协同决策框架		引入互评和监管机制的协同决策框架		基于分布式贝叶斯推断的多层级协同框架	
博弈时间	决策逻辑	决策结果	决策逻辑	决策结果	决策逻辑	决策结果	决策逻辑	决策结果
1	1.决策模型：根据目前的游戏状态，合作比例为0.46。建议实行适当的奖惩机制。 2.互评模型：根据当前数据，合作趋势较低，建议增加奖励，并进行适当惩罚。	奖励值：5； 惩罚值：-4	1.决策模型：根据当前的合作比例为 0.48 和背叛比例为 0.52，因此似乎参与者更有可能背叛而不是合作，为了鼓励合作，适当的奖励值是合适的。 2.监管模型：无决策	奖励值：3； 惩罚值：-2	1.决策模型：根据当前的合作比例为 0.62 和背叛比例为 0.38，目前反对比率较高，为了鼓励合作，适当的奖励值是合适的。 2.互评模型：根据当前合作趋势高于反对趋势。建议继续鼓励和支持合作行为，以进一步增强团队凝聚力和成就感。 3.监管模型：无决策	奖励值：1 惩罚值：-1	1.决策模型：根据当前游戏状态，合作比例为 0.54，为鼓励合作，将给予适当的奖惩值。 2.互评模型：根据当前数据，合作趋势较低，反对趋势较高。建议增加互动机会和奖励机制，以鼓励玩家之间的协作和沟通。 3.监管模型：无决策	奖励值：3； 惩罚值：-2
31	…	…	1.决策模型：在这一轮的游戏中，大语言模型根据监督者的反馈和当前合作比例为 0.18 进行了决策调整。 2.监管模型：监督者建议进一步提高奖励值以加强对合作行为的激励，并降低惩罚值以减少对非合作行为的负面影响。	奖励值：5； 惩罚值：-1	…	…	…	…
…	…	…	…	…	…	…	…	…

	引入互评机制的协同决策框架		引入监管机制的协同决策框架		引入互评和监管机制的协同决策框架		基于分布式贝叶斯推断的多层级协同框架	
100	1.决策模型：根据目前的游戏状态，合作比例为0.64。建议继续实行适当的奖惩机制。 2.互评模型：根据当前数据，合作趋势有所提高，建议增加奖励，并进行适当惩罚。	奖励值：5； 惩罚值：-3	1.决策模型：根据当前游戏状态，合作比例为0.54，背叛比例为0.46。因此，设定一个适度的奖惩值鼓励进一步的合作，并阻止背叛。 2.监管模型：无决策	奖励值：3； 惩罚值：-2	1.决策模型：目前合作比例为1，可维持现有激励保证合作行为。 2.互评模型：根据当前数据，建议保持现有激励措施。 3.监管模型：考虑到目前合作比例较低，建议加大奖励力度，并进行适当惩罚。	奖励值：3 惩罚值：-2	1.决策模型：当前游戏状态下，合作比例为1，可维持现有激励保证合作行为。 2.互评模型：根据当前数据，建议保持现有激励措施。 3.监管模型：无决策	奖励值：5； 惩罚值：-3



（a）Peer-Evaluated Collaborative Decision Model
（b）Regulated Collaborative Decision Model
（c）Peer-Reviewed and Regulated Collaborative Decision Model
（d）Distributed Bayesian Multilevel Decision Model
（e）Bayesian Inference Outcome

图 5 实验 3 中大语言模型决策结果

Figure 5: Decision Outcomes of Large Language Models in Experiment 3

首先，表7以及图5(a)、(b)、(c)和（d）分别展示了四种协同决策框架的决策文本及其结果。这四个框架分别为：具有互评机制的协同决策框架（简称模型1)、具有监管机制的协同决策框架（简称模型2)、具有互评和监管机制的协同决策框架（简称模型3）以及基于分布式贝叶斯推断的多层级协同框架（简称模型4）

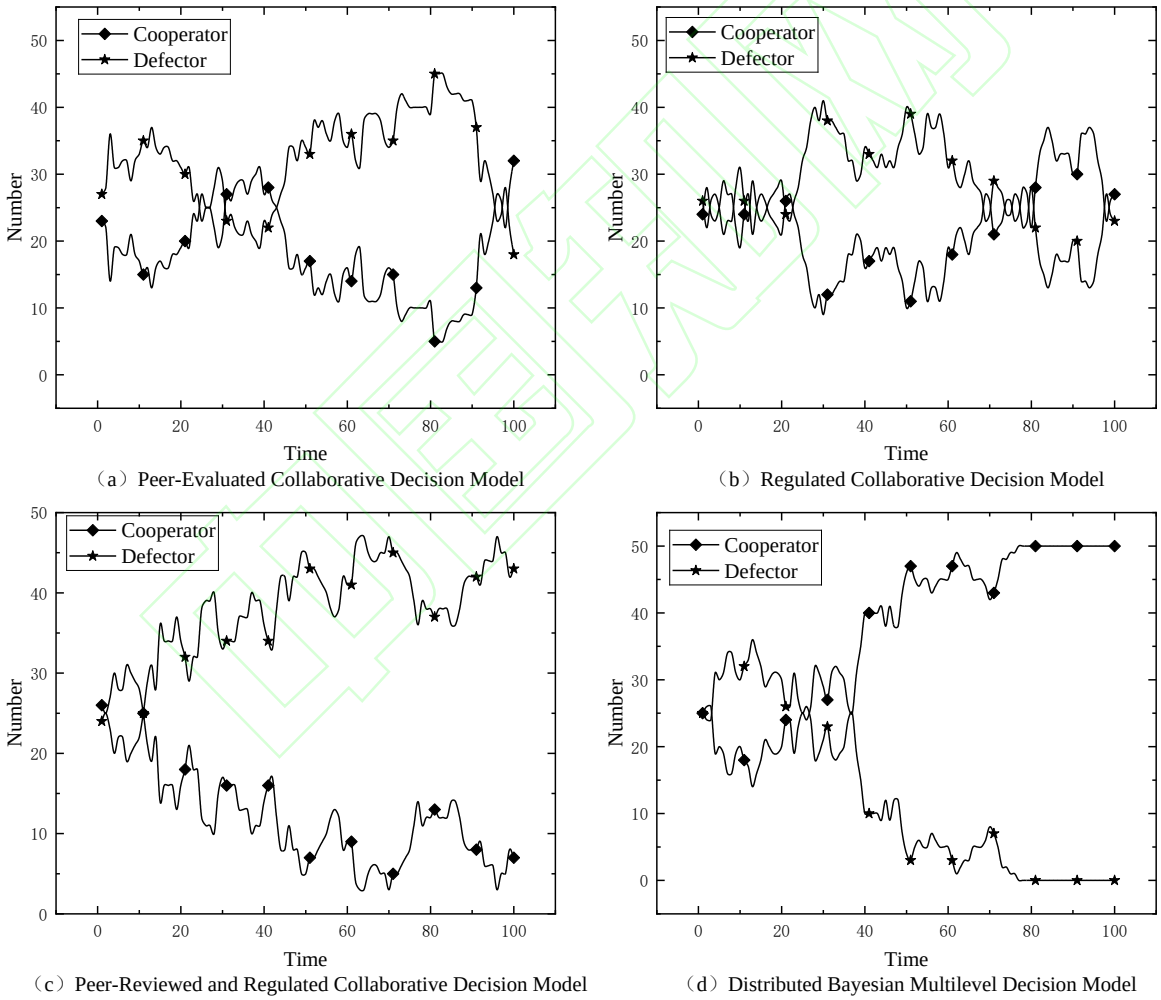
从实验结果可以看出，模型4的奖励值大多集中在5左右，惩罚值则稳定在-3左右，显示出较高的决策稳定性。相比之下，模型1和2的奖惩值波动幅度较大，且在某些情况下出现了错误决策。而模型3的奖惩值波动幅度比较模型1和2有所降低，其中惩罚值大多稳定在-2左右。

由图6的系统演化结果可知，图6(d)中的合作比例显著提升，并在博弈后期保持在较高水平。与另外的实验结果进行对比，不难看出模型4在模糊任务环境下的决策表现显著优于其余模型，这一结果验证了多层级协同框架的设计以及分布式贝叶斯推断方法的引入能够有效提升大语言模型的决策能力。同时，单独引入互评机制、监管机制或两者

结合的协同决策框架也能有效提升大语言模型的决策能力，且几者之间并无太大差异。

综合所有实验结果，可以得到以下两点结论：第一，大语言模型在面对复杂环境博弈中能够做出有效决策，且能够时刻灵活改动策略，展现出了较高的灵活性和适应性，但此博弈过程需要明确的提示工程指令。第二，在面对模糊任务的情况下，多个大语言模型协同决策显著提高了大语言模型的决策效率及质量，克服了单一大语言模型在模糊指令下的不良表现。通过多个模型的协作，不仅能够更好地理解和适应复杂的博弈环境，还可以通过相互监督和优化，逐步提升系统的整体合作效果。

而本文提出的基于分布式贝叶斯推断的多层级大语言模型协同决策模型，通过结合互评机制和监管机制，并引入分布式贝叶斯推断方法，进一步增强了多个大语言模型协同决策的决策能力，并且在处理不确定性和模糊任务时具有独特优势。通过引入互评机制，模型能够在决策过程中相互校正，减少错误决策的发生；而监管机制则确保了在关键节点上的决策一致性和决策方向。分布式贝叶斯推断的引入则为模型提供了一个动态的、数据驱动的决策依据，使得整个系统能够根据实时反馈不断优化决策策略。



（a）Peer-Evaluated Collaborative Decision Model

（b）Regulated Collaborative Decision Model

（c）Peer-Reviewed and Regulated Collaborative Decision Model

（d）Distributed Bayesian Multilevel Decision Model

图 6 实验 3 中多智能体博弈演化图

Figure 6: Evolutionary Diagram of Multi-Agent Game in Experiment 3

3.2 决策评价

为直观评估大语言模型的决策能力，本研究对上述实验中的大语言模型决策效果进行评估。本文首先定义了最优决策，并将最优决策视为合作比例和合作收益变化的最大值，即：

$$\Delta R_{\text{opt}} = \max(\Delta R) \tag{12}$$

$$\Delta P_{\text{opt}} = \max(\Delta P) \tag{13}$$

其中，ΔR 表示合作比例的变化，ΔP 表示合作收益的变化。

由此，大语言模型的决策能力将通过标准化欧几里得距离来衡量，即每个决策相对于最优决策的偏离程度，其中偏离值越低，表明大语言模型的决策效果越好，其计算公式如下：

$$E_i=\sqrt{\left(\frac{\Delta R_i-\Delta R_{\text{opt}}}{\Delta R_{\text{opt}}}\right)^2+\left(\frac{\Delta P_i-\Delta P_{\text{opt}}}{\Delta P_{\text{opt}}}\right)^2} \tag{14}$$

其中，E_i 是第 i 轮决策能力大小，ΔR_i 是第 i 轮的合作比例变化，ΔP 是第 i 轮的合作收益变化。

同时，决策效果的评估基于合作比例和合作收益的变化是否均为正，具体表达为：

$$D_i=\begin{cases}1 & \text{if } \Delta R_i>0 \text{ and } \Delta P_i>0\\ 0 & \text{otherwise}\end{cases} \tag{15}$$

其中，D_i 是第 i 轮策略的决策效果。1表示该策略在该轮次内有效地增加了合作比例和合作收益;值为0表示该策略未能增加合作比例或合作收益，或者两者之一有所减少。

根据上述公式计算，图7展示了三个实验的决策效应大小的统计分布情况，且由于部分实验中多智能体博弈已经提前达到完全合作或背叛，因此在评估和分析时，将剔除后续无效数据，以避免对其评价结果造成误差。

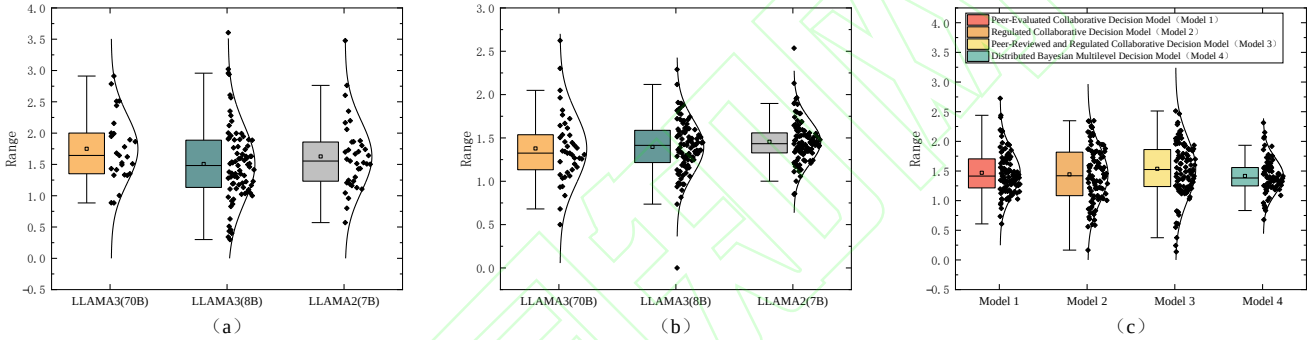


图 7 大语言模型决策评价结果分布

Figure 7: Distribution of Decision Evaluation Results for Large Language Models

根据图7（a）的结果可知，LLAMA3（70B）模型的决策评价指标中位数约为1.3，数据主要分布在较低的数值区间内，表明其在复杂博弈决策场景下展现出较优的表现。相比之下，LLAMA3（8B）和LLAMA2（7B）模型的决策评价指标中位数均约为1.4，其中LLAMA3（8B）的数据分布较为集中，四分位距较窄，显示出较好的一致性和稳定性。LLAMA2（7B）虽然中位数与LLAMA3（8B）接近，但在高值区间的数据分布较广，表明其在复杂博弈决策情境下的决策表现不够稳健。结合该评价指标及前文实验结果，说明在具有高决策精度要求的应用中，较大模型参数的LLAMA3（70B）能提供更为优越的决策建议。此外，LLAMA3（8B）相比LLAMA2（7B）在保持整体决策一致性方面表现出其优势。这些观察结果在一定程度上验证了大型语言模型参数增加对提升决策能力的积极效应。

根据图7（b）的结果，LLAMA3（70B）模型的决策评价指标中位数约为1.7，且显示出较宽的数据分布范围，相比于实验1中的表现，该模型在无明确任务指导下的决策表现有一定的下降。同样，LLAMA3（8B）的决策评价指标中位数约为1.5，且四分位距相较于实验1有所扩大；而LLAMA2（7B）的中位数也稍有上升，约为1.6，其四分位距也有明显增加。综合数据结果以及前文实验，表明在没有明确任务目标的情况下，各模型的决策表现普遍呈现下降趋势，并未能有效激励合作行为涌现。此外，这些结果也进一步表明了在模糊任务环境中，无论模型参数大小，其大语言模型在处理复杂决策过程时的性能仍然需要进一步优化。

根据图7（C）的结果可知，模型4的决策评价中位数约为1.4，且四分位距较窄，表明模型4在复杂决策环境中有较为优异的决策能力。相比之下，模型1、模型2以及模型3的中位数值较为接近，约为1.45，但模型3的四分位距较宽，但大多数数值位于低值区域，表明其决策更加接近最优决策。

接着，本研究计算了决策效应的平均值、标准差和方差，以量化策略性能的波动和可靠性。表 8 展示了其计算的结果。

表 8 大语言模型决策效应比较

Table **8: Comparison of Decision Effects for Large Language Models**

实验	模型	平均值	标准差	方差	正向效应策略	负向效应策略
实验 1	LLAMA3（70B）	1.379	0.406	0.165	12	29
	LLAMA3（8B）	1.395	0.317	0.101	34	65
	LLAMA2（7B）	1.456	0.252	0.063	13	86
实验 2	LLAMA3（70B）	1.737	0.534	0.285	2	27
	LLAMA3（8B）	1.490	0.558	0.312	22	77
	LLAMA2（7B）	1.621	0.558	0.311	8	30
实验 3	模型 1	1.470	0.375	0.141	18	81
	模型 2	1.436	0.470	0.221	33	66
	模型 3	1.545	0.525	0.276	14	85
	模型 4	1.413	0.297	0.088	17	61

在实验1中，LLAMA3（70B）模型的平均值为1.379，标准差为0.406，方差为0.165，具有12个正向效应策略和29个负向效应策略。相比之下，LLAMA3（8B）的平均值略高为1.395，但表现出更低的标准差（0.317）和方差（0.101），正向效应策略数为34，负向效应策略数为65，显示了更高的决策一致性。LLAMA2（7B）显示出最高的平均值（1.456），虽然标准差（0.252）和方差（0.063）较低，但数值大都分布在较高值域，其决策能力与另外两个模型稍显不足。

在实验2中，LLAMA3（70B）的决策能力显著下降，平均值增至1.737，标准差和方差也相应增加至0.534和0.285，正向效应策略为2，负向效应策略为27。LLAMA3（8B）和LLAMA2（7B）的标准差和方差均接近，显示出较高的决策偏离。对比可知，LLAMA3（70B）模型的决策误差较LLAMA3（8B）模型高出16.6%，较LLAMA2（7B）模型高出7.2%，这表明，在模糊任务指令下，大语言模型在处理复杂博弈问题时显示出明显的决策失灵现象。这一结果强调了未来在复杂的决策环境中，如何强化大语言模型的理解能力和分析能力是至关重要的。

与实验 2 相比，实验 3 中模型 1、模型 2、模型 3 以及模型 4 的平均偏离值分别降至 1.436、1.535 以及 1.470，其决策能力都有明显提升，其中模型 3 的平均决策偏离程度最高，表明其决策波动最大，这可能是由于多个模块的引入，导致了其决策能力的波动。此外，模型 1 的正向和负向效应策略数分别为 18 和 81，模型 2 为 33 和 66，模型 3 则为 14 和 85，模型 4 未 17 和 61。这些数据揭示了多个大语言模型间协同作用在处理复杂任务时的潜力和积极作用。表明了多模型协同在增强决策适应性和稳定性方面的有效性。因此，在设计和实施复杂任务决策过程中，可以考虑采用多模型协同策略，以此优化整体决策性能。

4 结束语

随着大语言模型的迅速发展，其能力备受关注。为解决在模糊任务目标下大语言模型在复杂博弈中存在的问题，本文提出了一种基于分布式贝叶斯推断的多层级大语言模型协同决策框架，从而有效解决了大语言模型在此博弈过程中的决策失灵现象，并通过多个实验检验了本文方法的优越性。此外，本文通过搭建大语言模型与多智能体博弈仿真框架，展示了大语言模型在模拟人类交互行为的应用潜力。

未来的工作可以分为多个方面。第一，可以继续深入研究大语言模型协同机制，例如设计不同的协同决策框架，探索多模型间的分工协作与任务分配策略，以提升模型在复杂任务下的决策效率。第二，可以重点研究在高度不确定性情境下模型的自适应能力，探索如何利用增强学习和在线学习等技术，使模型能够在环境变化时实时调整决策策略，从而增强其鲁棒性和适应性。第三，可以进一步扩展大语言模型协同决策的应用场景，并引入国产大模型进行对比实验，尤其是在中文环境下的特定领域任务（如医疗诊断、智能客服等），以此评估不同大语言模型之间的能力差异，从而为提升模型在本土化应用中的表现提供方向。

参考文献

[1] Kim,Junsol,Lee, et al. AI-Augmented Surveys: Leveraging Large Language Models and Surveys for Opinion Prediction[Z], 2023: arXiv:2305.09620.

[2] Organisciak,Peter,Acar, et al. Beyond semantic distance: Automated scoring of divergent thinking greatly improves with large language models[J]. Thinking Skills and

Creativity, 2023, 49: 101356.

[3] Webb,Taylor,Holyoak, et al. Emergent analogical reasoning in large language models[J]. Nature Human Behaviour, 2023, 7(9): 1526-1541.

[4] Qureshi,Riaz,Shaughnessy, et al. Are ChatGPT and large language models “the answer” to bringing us closer to systematic review automation?[J]. Systematic Reviews, 2023, 12(1).

[5] Contreras Kallens,Pablo,Kristensen-McLachlan, et al. Large Language Models Demonstrate the Potential of Statistical Learning in Language[J]. Cognitive Science, 2023, 47(3).

[6] Carvalho,Ines,Ivanov, et al. ChatGPT for tourism: applications, benefits and risks[J]. Tourism Review, 2024, 79(2): 290-303.

[7] Huang,Allen H.,Wang, et al. FinBERT: A Large Language Model for Extracting Information from Financial Text*[J]. Contemporary Accounting Research, 2023, 40(2): 806-841.

[8] Alqahtani,Tariq,Badreldin, et al. The emergent role of artificial intelligence, natural learning processing, and large language models in higher education and research[J]. Research in Social & Administrative Pharmacy, 2023, 19(8): 1236-1242.

[9] Xu,Yuzhuang,Wang, et al. Exploring Large Language Models for Communication Games: An Empirical Study on Werewolf[J]. Arxiv E-prints, 2023, abs/2309.04658: arXiv:2309.04658.

[10] Zhang,Jintian,Xu, et al. Exploring Collaboration Mechanisms for LLM Agents: A Social Psychology View[J]. Arxiv E-prints, 2023, abs/2310.02124: arXiv:2310.02124.

[11] Guo,Fulin. GPT in Game Theory Experiments[Z]: Arxiv, 2023: arXiv:2305.05516.

[12] Perc,Matjaz. Phase transitions in models of human cooperation[J]. Physics Letters a, 2016, 380(36): 2803-2808.

[13] Yuzhuang Xu,Shuo Wang,Peng Li, et al. Exploring Large Language Models for Communication Games:An Empirical Study on Werewolf[J]: 1-23.

[14] 陈娟,赵新潮,隋京言,等. 故事启发大语言模型的时序知识图谱预测_陈娟[J]. 模式识别与人工智能，2024, 37(08): 715-728.

Chen, J., Zhao, X., Sui, J., Qi, L., Tian, C., Pang, L., & Fang, J. (2024). Narrative-Driven Large Language Model for Temporal Knowledge Graph Prediction. Pattern Recognition and Artificial Intelligence, 37(08), 715-728. (in Chinese)

[15] 陶江垚,奚雪峰,盛胜利,等. 结构化思维提示增强大语言模型推理能力综述_陶江垚[J]. 计算机工程与应用: 1-21.

Tao, J., Xi, X., Sheng, S., Cui, Z., & Zuo, Y. Enhancing Large Language Models' Reasoning Abilities through Structured Thinking Prompts: A Review. Computer Engineering and Applications, 1-21. (in Chinese)

[16] 罗焕坤,葛一烽,刘帅. 大语言模型在数学推理中的研究进展_罗焕坤[J]. 计算机工程, 2024, 50(09): 1-17.

Luo, H., Ge, Y., & Liu, S. (2024). Research Progress of Large Language Models in Mathematical Reasoning. Computer Engineering, 50(09), 1-17. (in Chinese)

[17] Tang,Ming,Liao, et al. From conventional group decision making to large-scale group decision making: What are the challenges and how to meet them in big data era? A state-of-the-art survey[J]. Omega-international Journal of Management Science, 2021, 100: 102141.

[18] Siegenfeld,Alexander F.,Bar-Yam, et al. An Introduction to Complex Systems Science and Its Applications[J]. Complexity, 2020, 2020: 1-16.

[19] Zhu,Wei,Jiang, et al. Event-based consensus of multi-agent systems with general linear models[J]. Automatica, 2014, 50(2): 552-558.

[20] Wang,Shiyong,Wan, et al. Towards smart factory for industry 4.0: a self-organized multi-agent system with big data based feedback and coordination[J]. Computer Networks, 2016, 101: 158-168.

[21] Gao,Chen,Lan, et al. S3: Social-network Simulation System with Large Language Model-Empowered Agents[J]. Arxiv E-prints, 2023, abs/2307.14984: arXiv:2307.14984.

[22] Williams,Ross,Hosseinichimeh, et al. Epidemic Modeling with Generative Agents[J]. Arxiv E-prints, 2023, abs/2307.04986: arXiv:2307.04986.

[23] Mao,Shaoguang,Cai, et al. ALYMPICS: LLM Agents Meet Game Theory -- Exploring Strategic Decision-Making with AI Agents[Z], 2023: arXiv:2311.03220.

[24] Phelps,Steve,Russell, et al. Investigating Emergent Goal-Like Behaviour in Large Language Models Using Experimental Economics[J]. Arxiv E-prints, 2023, abs/2305.07970: arXiv:2305.07970.

[25] Akata,Elif,Schulz, et al. Playing repeated games with Large Language Models[Z]: Arxiv, 2023: arXiv:2305.16867.

[26] Guo,Jiaxian,Yang, et al. Suspicion-Agent: Playing Imperfect Information Games with Theory of Mind Aware GPT-4[Z]: Arxiv, 2023: arXiv:2309.17277.

[27] Suzuki,Reiji,Arita, et al. An evolutionary model of personality traits related to cooperative behavior using a large language model[J]. Scientific Reports, 2024, 14: 5989.

[28] Phelps,Steve,Russell, et al. Investigating Emergent Goal-Like Behaviour in Large Language Models Using Experimental Economics[J]. Arxiv E-prints, 2023, abs/2305.07970: arXiv:2305.07970.

[29] Xu,Lin,Hu, et al. MAgIC: Investigation of Large Language Model Powered Multi-Agent in Cognition, Adaptability, Rationality and Collaboration[J]. Arxiv E-prints, 2023: arXiv:2311.08562.

[30] Kai Xiong,Xiao Ding,Yixin Cao, et al. Examining Inter-Consistency of Large Language Models Collaboration: An In-depth Analysis via Debate[C]//Conference on Empirical Methods in Natural Language Processing, 2023.

[31] Xu,Zhenran,Shi, et al. Towards Reasoning in Large Language Models via Multi-Agent Peer Review Collaboration[J]. Arxiv E-prints, 2023: arXiv:2311.08152.

[32] Zhang,Bin,Mao, et al. Controlling Large Language Model-based Agents for Large-Scale Decision-Making: An Actor-Critic Approach[J]. Arxiv E-prints, 2023: arXiv:2311.13884.

[33] Touvron,Hugo, Lavril, et al. LLaMA: Open and Efficient Foundation Language Models[J]. Arxiv, 2023.

[34] Boccaletti,S.,Bianconi, et al. The structure and dynamics of multilayer networks[J]. Physics Reports-review Section of Physics Letters, 2014, 544(1): 1-122.

[35] Yang,Wenjing,Brenner, et al. Influence Maximization by Link Activation in Social Networks[C]//2018 Ieee 23rd International Conference on Emerging Technologies and Factory Automation (etfa), 2018: 1248-1251.

[36] Holme,Petter. Modern temporal network theory: a colloquium[J]. European Physical Journal B, 2015, 88(9).